

BRIEFING DO PROJETO INTEGRADOR

Disciplina: Hands-On Fundamentos de Dados e Analytics

Módulo 1 – MBA em Engenharia de Dados – Universidade Presbiteriana Mackenzie

Mentoria: Prof. Gustavo Ferreira

Projeto Kenzie 360

Documento consolidado — Sprints 1, 2 e 3 • Seções 1 a 12

Sobre este documento

Este é o briefing completo do projeto: reúne, em um único arquivo, as seções entregues ao longo das três sprints. As Seções 1 a 4 vêm da Sprint 1 (identificação, problema, objetivos e dados); as Seções 5 a 7, da Sprint 2 (Data Lake, análise exploratória e governança); as Seções 8 a 12, da Sprint 3 (MVP, ciclo de aprendizado, auditoria e modelagem preditiva).

O texto das seções 5 a 12 é idêntico ao dos briefings originais. Nas Seções 1 a 4, três pontos foram atualizados para que o documento não se contradiga: os números e os nomes de arquivo da base passaram a refletir a **versão 8**, que substituiu a versão original após a recalibração descrita na Seção 6.8; a descrição da base ganhou uma nota apontando essa substituição; e o terceiro objetivo específico, que na Sprint 1 deixava a variável-alvo do modelo em aberto, agora remete à Seção 11, onde ela foi definida. Nenhuma outra alteração de conteúdo foi feita.

Duas versões da análise circularam durante o projeto. Os números aqui apresentados são os da **revisão publicada na Sprint 3**, posterior à auditoria do gerador da base: a Seção 10 explica o que mudou, por que mudou e quais conclusões da Sprint 2 não sobreviveram à correção.

Sumário

Seção	Conteúdo	Sprint
1	Identificação do grupo	1
2	Descrição do problema de negócio	1
3	Objetivos do projeto	1
4	Dados utilizados	1
5	Arquitetura e implementação do Data Lake	2
6	Análise exploratória de dados e métricas	2
7	Governança, integração contínua e infraestrutura como código	2
8	Definição do MVP e levantamento de requisitos	3
9	Arquitetura do ciclo de aprendizado	3
10	Auditoria do gerador e revisão da análise	3
11	Modelagem preditiva — versão inicial	3
12	Próximos passos	3

1. IDENTIFICAÇÃO DO GRUPO

Nome do Projeto: Projeto Kenzie 360

Setor de Atuação: ☐ Varejo ☐ Saúde ☒ **Finanças** ☐ Logística ☐ Setor Público ☐ Outro

Integrantes:

Nome completo	E-mail	LinkedIn
Ilan David Schapira	ilanschapira@gmail.com	linkedin.com/in/ilan-david-s-156412135
Giovanna Caetano Protti	giovannacprotti37@gmail.com	linkedin.com/in/giovanna-caetano-protti-3a8859235
Jonathas Borges	jonathasborges94@gmail.com	linkedin.com/in/jonathas-borges-0827a0185

2. DESCRIÇÃO DO PROBLEMA DE NEGÓCIO

2.1 Qual é o problema que vocês pretendem resolver?

A “Kenzie”, bot de atendimento do banco, atende todos os correntistas, com forte concentração no público CDE (Conta de Domiciliado no Exterior – clientes não residentes). No entanto, a versão atual (V1) opera de forma reativa e “sem memória”: cada interação é tratada de maneira isolada, sem reter o histórico conversacional do cliente e sem transformar esses diálogos em conhecimento. Como consequência, o banco não consegue enxergar padrões nas dores recorrentes de sua base – com destaque para o público CDE, que enfrenta dificuldades com documentação no onboarding digital, dúvidas em operações de câmbio e problemas no primeiro acesso a partir do exterior, mas também abrangendo demandas comuns a todos os correntistas, como bloqueios inesperados de TED/PIX, alterações abruptas de limites e dúvidas sobre o portfólio (cartão de crédito e CDB). O problema central é a ausência de um “cérebro” analítico capaz de reter o histórico, gerar insights de negócio e antecipar tendências a partir dos atendimentos.

2.2 Qual é o impacto do problema para o negócio?

A fricção concentrada nas etapas de onboarding e nas operações do dia a dia eleva a taxa de abandono – de forma crítica entre os clientes não residentes – e reduz a ativação das contas, comprometendo a adesão aos únicos produtos ofertados (cartão de crédito e CDB). Além disso, a falta de aprendizado a partir das conversas aumenta o volume de transferências para atendimento humano, elevando o custo operacional, e faz o banco perder oportunidades de cross-sell e de retenção em toda a base de correntistas. Em termos estratégicos, atendimentos que não viram dado são receita e inteligência competitiva desperdiçadas: sem histórico estruturado, o banco decide no escuro sobre um público de alto valor e difícil aquisição.

3. OBJETIVOS DO PROJETO

3.1 Objetivo Geral

Estruturar a versão V2 da Kenzie, bot de atendimento aos correntistas do banco (com foco prioritário no público CDE), dotando-a de um “cérebro” analítico capaz de reter o histórico conversacional, gerar insights de negócio e antecipar tendências, por meio de uma arquitetura de dados em nuvem (GCP) que sustente análise exploratória, modelagem preditiva/classificatória (NLP) e visualização executiva.

3.2 Objetivos Específicos

- Construir e disponibilizar uma base estruturada de logs conversacionais completos (histórico turno a turno) do público atendido, alimentando um Data Lake em nuvem com camadas RAW, TRUSTED e CURATED sob uma arquitetura Lambda na GCP.
- Realizar Análise Exploratória de Dados (EDA) para identificar as dores recorrentes, padrões de sentimento, sazonalidade e principais motivos de transferência para atendimento humano.
- Desenvolver um modelo preditivo/classificatório de NLP sobre os atendimentos, gerando inteligência acionável de negócio. O objetivo e a variável-alvo, deixados em aberto na Sprint 1, foram definidos na Sprint 3 e estão detalhados na Seção 11.
- Construir um dashboard executivo no Google Looker Studio com os principais KPIs de atendimento e insights, apoiando decisões das áreas de negócio e produto.
- Aplicar princípios de governança de dados (catálogo, políticas de acesso e LGPD simulada) adequados ao tratamento de dados de clientes não residentes.

4. DADOS UTILIZADOS

4.1 Fonte de Dados

Base de dados sintética (fictícia), construída pela equipe como um “gêmeo estatístico” da operação: calibrada para reproduzir os padrões reais do atendimento — volume, mix de dores, taxa de resolução do bot, satisfação, desfechos (resolução pelo bot, transferência para atendimento humano, abandono e ruído) e sentimento. Não utiliza nenhum dado pessoal ou registro real de clientes, garantindo total conformidade com a LGPD. A modelagem baseou-se no conhecimento de negócio da equipe sobre os cenários reais enfrentados pelo banco, tendo como referência a operação de atendimento via WhatsApp (plataforma Take Blip).

Os logs são conversacionais completos (histórico turno a turno entre Cliente, a assistente Kenzie e o Atendente Humano), contemplam três segmentos — aproximadamente 70% de clientes CDE (não residentes), 27% de correntistas nacionais e 3% de PJ —, nove arquétipos de cliente (com estilos distintos de escrita: formalidade, abreviações, emojis, erros de digitação) e três idiomas (português, inglês e espanhol). O sentimento é derivado do próprio texto das mensagens, permitindo modelagem de NLP legítima, sem vazamento de informação.

Governança aplicada: reproduzindo um export real, o cliente eventualmente digita dados pessoais no chat (CPF, telefone, e-mail, conta). Um pipeline de mascaramento substitui esses valores por marcadores ([CPF], [TELEFONE], [EMAIL], [CONTA]) antes da persistência, e o identificador do cliente é pseudonimizado por hash — LGPD by design. O fluxo conversacional completo está especificado no documento “Fluxo Conversacional da Kenzie”.

A base descrita abaixo é a **versão 8**, resultado da recalibração motivada pelos achados da EDA e documentada na Seção 6.8. É a base que sustenta todas as análises e o modelo apresentados neste documento.

4.2 Descrição da base (duas tabelas)

Tabela	Arquivo	Dimensões
Conversas	dataset_kenzie360_atendimentos_v8.csv	36.000 linhas × 30 colunas
Mensagens (histórico)	dataset_kenzie360_mensagens_v8.csv	405.073 linhas × 12 colunas

Clientes distintos: 15.000 — 39,8% com mais de um atendimento e 17,8% de reaberturas.

Período coberto: 17/02/2026 a 17/08/2026 (182 dias, média de 197,8 conversas por dia).

4.3 Principais variáveis

Nome	Tipo	Significado	Tratamento?
segmento_cliente	Categoria	CDE, Correntista Nacional ou PJ	Não
arquetipo	Categoria	Perfil do cliente (9 arquétipos)	Não
idioma	Categoria	PT / EN / ES	Não
origem	Categoria	Receptivo ou Ativo (disparo do banco)	Não
categoria_assunto	Texto	Dor/tema do cliente	Não
texto (mensagens)	Texto	Cada fala do diálogo — base para NLP	Sim (limpeza)
sentimento	Categoria	Por fala do cliente, derivado do texto	Não
status_conversa	Categoria	Desfecho (10 estados: resolvida, abandonada, opt-out, ruído...)	Não

Nome	Tipo	Significado	Tratamento?
resolvida	Categoria	Sim / Não / Desconhecido / Não aplicável	Não
transferencia_iniciada	Booleano	Bot escalou o caso	Não
humano_atendeu	Booleano	Humano efetivamente assumiu (fila x atendimento)	Não
area_encaminhada	Texto	Área que recebeu o caso (triagem)	Não
tipo_midia	Categoria	texto / imagem / áudio	Não
reabertura	Booleano	Cliente voltou após caso não resolvido	Não
csat	Numérico	Nota de satisfação (1-5), ~70% em branco	Sim (nulos)
contem_dado_mascarado	Booleano	Mensagem teve PII mascarada (LGPD)	Não

Tabela de conversas (30 colunas): id_conversa, id_cliente (pseudonimizado), segmento_cliente, arquetipo, perfil_tecnologico, faixa_etaria, idioma, origem, data_hora, canal_entrada, canal_humano, categoria_assunto, produto_relacionado, primeira_mensagem_cliente, sentimento_geral, resolvido_bot, transferencia_iniciada, humano_atendeu, status_conversa, resolvida, area_encaminhada, motivo_transferencia, num_mensagens, num_mensagens_cliente, duracao_seg, csat, qtd_dados_mascarados, transcricao_completa, contatos_previos e reabertura.

Tabela de mensagens (12 colunas): id_conversa, id_cliente, segmento_cliente, idioma, categoria_assunto, ordem, timestamp, remetente (Cliente / Kenzie / Atendente Humano), texto, sentimento, tipo_midia e contem_dado_mascarado. A transcrição segue formato padronizado: “[NN] Remetente: texto”, separado por “ || ”.

5. ARQUITETURA E IMPLEMENTAÇÃO DO DATA LAKE

5.1 Da arquitetura lógica à implementação

A Sprint 1 desenhou a arquitetura Lambda na GCP, mapeando as camadas Batch, Speed e Serving ao modelo RAW → TRUSTED → CURATED. A Sprint 2 implementou esse desenho no BigQuery.

Camada do Lake	Implementação	Papel
RAW (bronze)	kenzie360_bronze	Registro imutável da origem, tudo em STRING, com rastreabilidade
TRUSTED (silver)	kenzie360_silver	Tipado, deduplicado, particionado, PII tratada
CURATED (gold)	kenzie360_gold	9 views e 1 dimensão, cada uma justificada por um achado

O bucket `gs://kenzie360-raw-ids26` no Cloud Storage guarda os arquivos originais antes da ingestão, versionados por data. Projeto GCP: `kenzie-360-mba`, região `us-central1`.

5.2 Decisões técnicas e suas justificativas

As decisões abaixo foram tomadas a partir da inspeção da base, não por convenção.

Decisão	Escolha	Por quê
Tipo de data_hora	DATETIME	A origem não declara fuso horário. Converter para UTC seria inventar informação
Campo resolvida	STRING	Tem 4 valores (Sim/Não/Desconhecido/Não aplicável). Tratar como booleano perderia a distinção entre 'não resolveu' e 'não se aplica'
Particionamento	Por data_ref (DATE)	Sem partição, cada consulta varreria as 405 mil mensagens inteiras
Clustering	segmento, categoria, idioma	São exatamente os filtros mais usados na análise e no dashboard
Camada gold	Views, não tabelas	Não ocupam armazenamento e nunca ficam defasadas
Conversões	SAFE_CAST	Valor inesperado vira NULL e aparece na validação, em vez de quebrar a carga

5.3 O detalhe que quase corrompeu a ingestão

A inspeção da base encontrou 4.361 linhas na tabela de atendimentos e 4.842 na de mensagens contendo ponto e vírgula dentro de campos de texto — o mesmo caractere usado como separador do arquivo.

Exemplo real: "Encaminhei para a área de Mesa de Limites; retornaremos em até 48h."

Esses campos vêm corretamente protegidos por aspas duplas, e a prova é que o número de linhas com aspas coincide exatamente com o de linhas com campo extra. A carga só funciona porque declara o caractere de aspas explicitamente. Sem isso, os registros quebrariam em colunas adicionais sem gerar erro — corrupção silenciosa.

5.4 Modelagem dimensional para consumo analítico

Além das três camadas do Lake, foram implementados os dois modelos de consumo previstos nos entregáveis da disciplina, ambos na camada CURATED.

Star Schema — modelo estrela com grão de um atendimento, composto por uma tabela fato e seis dimensões conformes:

Objeto	Registros	Conteúdo
fato_atendimento	36.000	Grão de um atendimento. Métricas, flags e as seis chaves estrangeiras. Particionada por data e clusterizada
dim_tempo	182	Calendário completo, inclusive dias sem movimento, para séries temporais sem lacunas
dim_cliente	15.001	Perfil e métricas de relacionamento: recorrência, primeiro e último contato, faixa de recorrência
dim_assunto	13	Categoria, produto e a classificação por tipo de ação exigida
dim_canal	9	Canal de entrada, canal humano e origem do contato
dim_desfecho	11	Status, cluster de satisfação e modo de falha
dim_motivo_transferencia	47	Motivo, área de encaminhamento e natureza da limitação

As dimensões carregam a inteligência da análise, e não apenas rótulos. A dimensão de assunto já traz o tipo de demanda — informacional, misto ou transacional — que foi o corte revelador da causa do problema. A de desfecho já traz o cluster de satisfação, porque a análise mostrou que o CSAT é bimodal. A de motivo classifica a natureza da limitação: falta de permissão transacional ou necessidade de julgamento humano. Isso evita que cada consulta recalcule as mesmas regras de negócio.

Cada dimensão possui um membro "não aplicável" com chave zero, garantindo que nenhuma linha da fato fique órfã. A validação automática confirmou integridade referencial completa: zero órfãs nas seis dimensões.

Wide Table — a view `vw_wide_atendimento` entrega o mesmo modelo já desnormalizado, com todas as dimensões resolvidas numa única linha por atendimento. Dispensa junções para treino de modelos e exploração rápida, e é também o caminho mais direto para conectar o Looker Studio, por não exigir configuração de relacionamentos.

Chaves substitutas: geradas por função de hash sobre a chave natural, e não por sequência numérica. A consequência é que recarregar a base produz exatamente as mesmas chaves — o modelo dimensional é tão reproduzível quanto o restante da pipeline.

5.5 Reprodutibilidade

Todo o ambiente é recriável a partir dos scripts que acompanham esta entrega, e cada script valida o próprio resultado, abortando se a contagem divergir do esperado:

- `gerar_dataset_cde_v8.py` — gera a base (SEED = 42, determinístico)
- `01_carga_bronze.py` — envia ao Cloud Storage e carrega a camada bronze

- 02_cria_silver.py — executa o DDL da silver com validação
- 06_cria_gold.py — cria e valida as views da gold
- 05_inventario_bq.py — inventário com checagem de duplicação

Os DDLs ficam versionados em arquivos .sql separados do código Python que os executa, permitindo revisão do SQL sem leitura de código.

6. ANÁLISE EXPLORATÓRIA DE DADOS E MÉTRICAS

6.1 Metodologia

A análise foi conduzida em 22 consultas SQL versionadas sobre a camada silver — 16 exploratórias e 6 de teste direto da hipótese do projeto. Cada consulta grava seu resultado em arquivo próprio, permitindo auditoria independente dos números apresentados.

6.2 A hipótese e o veredito

O projeto parte de uma tese sobre por que a Kenzie V1 não entrega:

(a) O script do bot não resolve por conta própria — sabe informar, não sabe executar. **(b)** Por isso a operação depende cronicamente do atendimento humano. **(c)** E o próprio atendimento humano falha, porque a demanda circula entre áreas internas do banco.

Os três eixos foram testados separadamente e todos se confirmaram.

Eixo	Veredito	Evidência central
(a)	Confirmado	A resolução pelo bot cai de 45,9% em demandas informacionais para 20,9% em transacionais. E 47,7% de toda a demanda é transacional
(b)	Confirmado	11.106 horas humanas por ano (6,3 postos em tempo integral) para uma autonomia de apenas 25,2%
(c)	Confirmado	15,9% dos casos que chegam ao atendimento humano terminam sem resolução, consumindo 1.770 horas por ano — e outros 1.481 clientes desistem na fila antes de serem atendidos

6.3 O problema não é linguagem, é permissão

Reclassificando as demandas pelo tipo de ação que exigem — e não pelo assunto — o padrão aparece com nitidez:

Tipo de demanda	% do total	Bot resolve	Pede humano	CSAT
Informacional (só consultar)	18,4%	45,9%	37,0%	3,87
Misto (consulta + ação leve)	20,1%	33,8%	45,0%	3,76
Transacional (exige sistema)	47,7%	20,9%	54,4%	3,65

Quatro indicadores se movem juntos e na mesma direção. A Kenzie entende o pedido — o que ela não tem é permissão de escrita nos sistemas do banco. Desbloquear um PIX, aprovar um documento ou alterar um limite exige executar uma transação, e o bot só sabe devolver texto.

Consequência para a V2: o ganho de automação não virá de treinar melhor o modelo de linguagem, e sim de conceder ao bot acesso transacional aos sistemas internos, com as travas de segurança correspondentes. É decisão de arquitetura e de apetite a risco, não de processamento de linguagem.

6.4 O custo da dependência

O bot resolve em 5,2 minutos, contra 24,6 do atendimento humano — e com satisfação maior (CSAT 4,34 contra 4,19). Não existe, nesta operação, o trade-off clássico entre custo e qualidade: automatizar melhora os dois.

Cenário de autonomia do bot	Ganho anual	Equivalente
+10 pontos percentuais	2.328 horas	1,3 FTE
Chegar a 40%	3.445 horas	2,0 FTE
Chegar a 50%	5.773 horas	3,3 FTE
Chegar a 60%	8.101 horas	4,6 FTE

Este é o business case da V2 em uma linha: cada 10 pontos percentuais de autonomia devolvem 1,3 posto de atendimento em tempo integral. E, pelo eixo (a), sabe-se exatamente onde esses pontos estão — nos 47,7% de demanda transacional hoje bloqueada.

6.5 O encaminhamento que consome atendimento e não resolve

O eixo (c) foi medido sobre o conjunto de conversas em que um atendente humano efetivamente assumiu o caso — 13.567 no período, e não sobre as 6.744 que trazem área registrada, que é um subconjunto enviesado. A operação perde de duas formas:

Modo de perda	Volume	O que acontece
Desiste na fila	1.481 / ano	Escalou para atendimento humano e desistiu antes de ser atendido — 9,8% de todas as escalações. O cliente nunca chegou a falar com uma pessoa
Atendido sem solução	2.158 / ano	Um atendente trabalhou o caso por 24,4 minutos — praticamente o mesmo tempo de um caso resolvido — e o cliente saiu sem solução. São 15,9% dos casos atendidos

Juntas, as duas perdas somam 3.639 conversas por ano — 10,1% da operação — que consumiram atendimento e não entregaram resultado. As 2.158 atendidas sem solução equivalem a 1.770 horas de atendente por ano, ou 15,8% de todo o tempo humano da operação. Não há economia de esforço no fracasso: o caso que falha custa praticamente o mesmo que o caso que dá certo.

Medidas sobre o denominador correto, as nove áreas internas resolvem entre 81,7% e 88,5% do que recebem, e a diferença entre elas não sobrevive a um teste de significância: oito das nove ficam dentro de 1,25 desvio-padrão da média. Esta base, contudo, não permite concluir que as áreas sejam equivalentes na operação real — o gerador do gêmeo estatístico atribui a todas a mesma probabilidade de resolução, de modo que a uniformidade observada é uma decisão de modelagem e não um achado empírico. Numa operação real a expectativa é a oposta: áreas com dependência de terceiros, restrição regulatória ou sem permissão de escrita nos sistemas de origem tendem a devolver mais casos. Testar isso exige que a área de destino seja registrada em todos os encaminhamentos, e não apenas quando o caso dá errado — requisito de captura de dado que fica registrado para a V2.

6.6 Demais achados relevantes

Achado	Evidência
A satisfação é bimodal	Quem tem o problema resolvido dá entre 3,94 e 4,34; quem não tem, entre 1,75 e 1,87. Não há nenhum desfecho no intervalo. A média de 3,74 é artefato aritmético e não descreve nenhum cliente
O atrito acumulado (premissa modelada)	A resolução cai de 29,9% no primeiro contato para 15,4% a partir do quinto, e a insatisfação sobe de 22,0% para 36,6%. Estes números não são um achado da análise: são a consequência aritmética do atrito acumulado, estrutura deliberadamente introduzida na recalibração da base (seção 6.8). O que eles dimensionam é o custo dessa premissa, dada a intensidade modelada
Não há barreira de idioma	Dentro do segmento CDE, a variação entre português, inglês e espanhol é de 0,5 ponto percentual
Vale de frustração no meio da conversa	54,5% das falas do terceiro quinto são negativas; o humor só melhora no trecho final
Bloqueio de TED/PIX é a pior dor	14,3% de resolução pelo bot, 58,9% de transferência e a maior duração média

Sobre a ausência de barreira de idioma: este resultado refuta uma hipótese inicial da própria equipe e foi mantido no relatório porque elimina a explicação concorrente mais fácil. A Kenzie atende igualmente mal em três idiomas e nos dois segmentos, o que reforça que a causa é estrutural. O que de fato distingue o cliente CDE é o produto: câmbio, praticamente exclusivo desse público, é demanda transacional pura.

6.7 Um alerta metodológico: composição versus desempenho

Consultando o modelo dimensional, observa-se que, entre as demandas informacionais, o bot resolve 42,5% dos atendimentos de clientes CDE contra 53,6% dos correntistas nacionais — onze pontos percentuais de diferença no tipo de demanda mais simples. À primeira vista, isso contradiz o achado de que não há penalização do público CDE.

A diferença, porém, é integralmente explicada pela composição do grupo, e não por qualidade de atendimento:

Categoria dentro de Informacional	% no CDE	% no Nacional	Bot resolve
Termos e Documentação BR	47,6%	8,0%	29,3%
Investimentos CDB	28,6%	52,0%	49,4%
Saldo e Extrato	23,8%	40,0%	61,1%

Aplicando essas proporções às taxas de cada categoria, a resolução esperada é de 42,9% para o CDE e 52,4% para o nacional — praticamente idêntica à observada. O bot atende os dois públicos com a mesma eficácia dentro de cada categoria; o que difere é a distribuição das perguntas.

O achado de negócio: quase metade das dúvidas informacionais do cliente CDE são sobre termos e documentação brasileira — o que é CPF, como funciona o PIX, se o CPF continua válido morando fora. São perguntas de quem não convive com o sistema financeiro brasileiro, e é justamente a categoria informacional com menor resolução. Não se trata de uma limitação de capacidade do bot, e sim de uma lacuna de conteúdo específica desse público, resolvível com material explicativo dedicado.

Este caso ilustra por que a análise agregada exige cuidado: comparar dois grupos com composições diferentes produz conclusões enganosas. O modelo dimensional permitiu identificar e quantificar o efeito.

6.8 Recalibração da base a partir dos achados

A análise exploratória identificou cinco limitações no próprio gerador da base sintética. Três foram corrigidas em uma nova versão:

Limitação	Problema	Correção
Sazonalidade	Volume diário plano (variação de 7,7%); segunda-feira igual a domingo	Efeito de dia da semana, vencimento de fatura, tendência e picos de incidente. Variação passou a 30,6%
Fuso horário	90% do volume entre 8h e 19h de Brasília, embora 70% da base resida no exterior	Cada cliente CDE recebe um fuso, e seu horário comercial local é convertido para o de Brasília
Atrito acumulado	Ser reabertura não alterava o desfecho: o cliente na quarta tentativa era tratado como se fosse a primeira	Contatos prévios e reabertura passam a reduzir a resolução e elevar abandono e insatisfação

A recalibração preservou os níveis agregados calibrados com a operação real — resolução pelo bot 25,2%, transferência 41,8%, abandono 17,3%, CSAT 3,74, com desvio máximo de 0,3 ponto percentual. O que mudou foi a distribuição interna, não os totais. O schema permaneceu idêntico, e a pipeline absorveu a mudança sem alteração de código.

7. GOVERNANÇA, INTEGRAÇÃO CONTÍNUA E INFRAESTRUTURA COMO CÓDIGO

7.1 Governança de dados

O controle de acesso segue o princípio de menor privilégio, com papéis específicos em vez do papel genérico de Editor:

Camada	Quem acessa	Papel atribuído
bronze	Esteira de ingestão	BigQuery Data Editor
silver	Engenharia de dados	BigQuery Data Editor
gold	Analistas e Looker Studio	BigQuery Data Viewer

Rastreabilidade: as colunas `_ingestion_ts` e `_source_file` acompanham cada registro da bronze até a silver, permitindo responder de onde veio e quando entrou qualquer linha da base.

Versionamento de dados: a promoção de uma nova versão da base preserva a anterior em tabelas com sufixo próprio, nos dois datasets. Ambas permanecem consultáveis e comparáveis em SQL.

LGPD: a base é 100% sintética e nenhum dado pessoal foi utilizado. Ainda assim, o pipeline de mascaramento está implementado na transição bronze → silver, aplicando expressões regulares para e-mail e CPF e registrando em coluna própria quando a regra atuou. Telefone ficou deliberadamente de fora: o padrão colide com valores monetários e números de protocolo, e um falso positivo destruiria dado legítimo. Na base atual a regra não encontra ocorrências — os dados já nascem mascarados por construção — mas ela permanece porque em produção a origem é um export real, onde essa garantia não existe.

A bronze preserva o texto como veio e é a camada de acesso mais restrito; a silver entrega a versão tratada. Quem consulta a silver não precisa ver o original.

7.2 Integração contínua e infraestrutura como código

A entrega separa três trilhas de pipeline independentes que compartilham a mesma base de infraestrutura como código, evitando que uma mudança no modelo force o redeploy de toda a infraestrutura:

Trilha	O que entrega	Situação
Infraestrutura (Terraform)	Buckets, datasets, IAM e políticas de acesso	Implementada e em operação
Pipeline de dados	Cargas e transformações bronze → silver → gold	Scripts versionados; esteira prevista
Pipeline de ML	Treino, avaliação e publicação do modelo de NLP	Prevista; depende da definição do alvo

Repositório: <https://github.com/MACK-Hand-on/MACK> — público. O histórico de revisão, o Pull Request com o plano do Terraform publicado como comentário e as execuções da esteira ficam visíveis na aba Actions.

A trilha de infraestrutura foi implementada e exercitada de ponta a ponta. Nenhuma alteração de infraestrutura chega ao ambiente sem passar por quatro controles encadeados:

Etapa	Controle aplicado
Abertura do Pull Request	Verificação automática de formatação, sintaxe, boas práticas de GCP (tflint) e segurança (checkov)
Revisão	O plano de execução do Terraform é publicado como comentário no próprio PR, legível por quem não domina a ferramenta
Merge	A branch principal exige Pull Request aprovado por outra pessoa; escrita direta, reescrita de histórico e exclusão estão bloqueadas
Aplicação	Parada obrigatória aguardando aprovação humana registrada, com o comentário do aprovador gravado no histórico

Autenticação: via Workload Identity Federation, sem chaves estáticas de conta de serviço armazenadas como segredos. O GCP confia em uma identidade emitida pelo GitHub para um repositório específico, e a autorização é dupla: uma condição no provedor restringe a organização de origem e um vínculo na conta de serviço restringe o repositório exato. Não existe arquivo de credencial que possa vaziar — decisão especialmente relevante em ambiente bancário, onde credenciais de longa duração representam risco desproporcional.

Adoção do ambiente existente: os recursos provisionados manualmente na fundação foram incorporados ao Terraform por importação, e não recriados. A alternativa — aplicar o código como estava — teria criado um segundo conjunto de recursos vazio ao lado do que contém os dados. O plano resultante foi lido três vezes antes da aplicação: localmente, como comentário no PR e na tela de aprovação. O resultado da execução foi de 4 recursos alterados e nenhum destruído, idêntico ao previsto.

Separação de responsabilidades: na execução registrada, quem revisou e mesclou o código e quem autorizou a alteração da infraestrutura foram pessoas distintas, em dois pontos de controle diferentes. A separação não foi combinada previamente — decorre do desenho da esteira, que é precisamente o objetivo de um controle automatizado.

7.3 O que a automação encontrou

O argumento a favor de uma esteira de verificação costuma ser apresentado como boas práticas. Neste projeto ele pôde ser verificado: a automação expôs três problemas reais que a revisão humana não havia detectado.

Achado	Como apareceu e o que significava
Módulo sem declaração de dependências	O tflint apontou, na primeira execução, que o módulo de data lake não declarava versão do Terraform nem do provedor. O módulo funcionava por herdar a configuração de quem o chamava — uma dependência implícita, que quebraria de forma silenciosa se reutilizado em outro contexto. O achado passou por duas revisões humanas antes de a ferramenta encontrá-lo em fração de segundo.
Bucket de dados crus sem	O plano do Terraform revelou que a política do bucket estava como

Achado	Como apareceu e o que significava
proteção contra exposição pública	herdada, e não imposta. A aplicação a corrigiu para imposta, além de ligar o versionamento de objetos. A infraestrutura como código não apenas documentou o ambiente: corrigiu uma lacuna de segurança que existia no provisionamento manual.
Ambiente de aprovação sem regra de proteção	O GitHub cria automaticamente qualquer ambiente citado em um fluxo de trabalho, sem nenhuma regra associada. O ambiente de produção existia nessa condição: aparentava ser um portão de aprovação e não era. Só foi detectado ao consultar suas regras por API, e não pela interface, que exibe o ambiente como existente.

Os três achados têm a mesma natureza: são controles que existiam no papel e não no sistema. Nenhum apareceria em teste funcional, porque nada estava quebrado — apenas desprotegido.

Uma dependência documentada que se materializou: o registro técnico do projeto anotou que transferir o repositório de propriedade invalidaria a configuração de autenticação, e que o ajuste precisaria acompanhar a transferência. Doze horas depois o repositório foi transferido para uma organização. A correção estava escrita e levou dois comandos, sem migração e sem perda de dado. Sem o registro, o sintoma seguinte teria sido uma falha genérica de permissão, sem nenhuma alteração de código que a explicasse.

7.4 Adequação da proposta ao orçamento do projeto

A proposta original de arquitetura foi revista para caber no Free Tier da GCP, mantendo o desenho conceitual e substituindo serviços cujo custo inviabilizaria o projeto acadêmico:

Serviço proposto	Restrição	Substituição adotada
Cloud Composer	Sem free tier; custo aproximado de US\$ 525 por mês em operação contínua	Cloud Scheduler com Cloud Run Jobs, ou consultas agendadas do BigQuery
Dataflow (streaming)	Cobrança por worker-hora mesmo ocioso	Assinatura do Pub/Sub que grava diretamente no BigQuery
DLP API	Serviço pago	Mascaramento por expressão regular em SQL, já implementado
Dataplex	Complexidade e custo desproporcionais ao escopo	Policy tags e segurança em nível de coluna, nativos do BigQuery

O Cloud Composer permanece documentado como arquitetura alvo para um ambiente bancário de produção, com o trade-off de custo explicitado. A escolha é consciente, não uma limitação técnica.

Nota sobre o bootstrap: a fundação do ambiente — projeto, APIs e o bucket que guarda o estado do próprio Terraform — foi provisionada manualmente. Fazer o Terraform criar o bucket onde guarda seu estado configuraria uma dependência circular; a separação entre bootstrap manual e recursos versionados é a prática padrão. Os demais recursos, antes provisionados à mão, passaram ao controle do Terraform por importação.

7.5 Custo efetivo do ambiente

Recurso	Consumo	Franquia mensal	Uso
Armazenamento no BigQuery	0,543 GiB	10 GiB	5,4%
Consultas processadas	380 MB	1 TiB	0,04%

Alerta de orçamento configurado em US\$ 20 mensais, com avisos em 10%, 50% e 90% do limite.

7.6 Próximos passos

- Publicar o protótipo do dashboard executivo no Looker Studio
- Ratificar em grupo a variável-alvo do modelo preditivo/classificador de NLP, definida em 28/08 e detalhada abaixo
- Versionar o código da pipeline de dados em repositório próprio, estendendo a ele o mesmo padrão de promoção por Pull Request já em operação na infraestrutura
- Atualizar as ações da esteira que ainda declaram a versão do Node.js em processo de descontinuação pelo GitHub

Quanto ao segundo item, os candidatos foram testados diretamente na base antes de qualquer treino, medindo o teto de desempenho de cada um. A classificação do motivo de transferência mostrou-se inviável: o campo é atribuído por sorteio uniforme no gerador, sem vínculo com texto, assunto ou cliente, o que limita qualquer modelo a 20% de acurácia — o acaso. A previsão de descadastro foi descartada por decorrer de uma regra determinística do próprio gerador. A opção adotada é um pipeline de dois estágios: um classificador de intenção, que deriva do texto de abertura a categoria da demanda e, por mapeamento determinístico, a área de encaminhamento; e sobre ele um escore de risco, que estima a probabilidade de o bot resolver o caso. O segundo estágio é avaliado por AUC e calibração, e não por acurácia — como classificador ele supera em apenas 2,1 pontos percentuais a regra trivial de prever sempre a classe majoritária, enquanto como escore de risco alcança um teto de AUC de 0,750. O resultado a ser reportado é o AUC obtido em relação a esse teto.

8. DEFINIÇÃO DO MVP E LEVANTAMENTO DE REQUISITOS

8.1 O que a Kenzie 360 é

A Kenzie 360 é a camada de inteligência que transforma conversa em decisão. Ela lê a abertura de cada atendimento, estima o risco de o bot não conseguir resolver, e roteia o caso antes que o cliente perceba que entrou no caminho errado. É a fundação sobre a qual a V2 do bot será construída, e o mecanismo pelo qual essa V2 aprende.

Esta definição responde a uma lacuna apontada na avaliação da Sprint 2: o projeto apresentava a implementação técnica sem declarar qual produto ela constrói. As três leituras possíveis — uma memória conversacional, um bot, a fundação da V2 — foram resolvidas em favor da terceira, com a primeira como meio e a segunda como consequência futura, fora do escopo deste semestre.

A Kenzie 360 explicitamente **não é**: a V2 do bot, que escreveria respostas e conversaria; um relatório, já que a saída principal é uma decisão tomada durante o atendimento e não um documento lido depois; e não é um modelo treinado uma única vez, porque o processo de aprendizado contínuo faz parte do produto.

8.2 Quem consome a saída, e o que muda

O mesmo motor serve dois consumidores em latências diferentes, e eles correspondem exatamente às duas camadas da arquitetura Lambda adotada no projeto.

O bot, na abertura da conversa — camada de velocidade. Entra o texto da primeira mensagem, sai a rota. Hoje toda conversa entra no script e o cliente descobre que o bot não resolve depois de catorze minutos; com a Kenzie 360 o caso de alto risco vai direto ao atendimento humano com contexto, e a decisão acontece no primeiro turno. A decisão é automática: não há aprovação humana prévia, porque o cliente está aguardando na conversa e não existe supervisor capaz de aprovar roteamento ao vivo em escala.

O supervisor, depois — camada de lote e serviço. Ele vê a fila do que já foi roteado, com a probabilidade que gerou cada decisão, e pode marcar um caso como roteado incorretamente. Essa marcação é o rótulo que alimenta o retreino. O supervisor não é um portão de aprovação: é a fonte de aprendizado do sistema. Sem esse papel, o modelo é treinado uma vez e envelhece em silêncio.

8.3 A decisão de negócio que muda, e a assimetria que a orienta

Antes, a operação descobre que uma demanda não tinha solução no bot depois de gastar o tempo do bot, o tempo da fila e a paciência do cliente. Depois, ela decide na abertura onde cada caso deve ser resolvido, e passa a saber quanto custa cada erro dessa decisão.

Erro de roteamento	Custo
Encaminhou ao humano um caso que o bot resolveria	Tempo de atendente. O cliente é bem atendido
Manteve no bot um caso que vai falhar	O cliente percorre a jornada que falha, se irrita e, pelo atrito acumulado (seção 6.6), volta em pior situação e é atendido em pior situação

O segundo erro é mais caro, e seu custo não termina naquela conversa. **A política de roteamento deve, portanto, pender para rotear demais, e não de menos.**

8.4 Requisitos do MVP

Requisitos funcionais:

- RF1 — classificar a intenção a partir do texto de abertura

- RF2 — estimar a probabilidade de resolução pelo bot
- RF3 — devolver uma rota: seguir no bot, ou encaminhar ao humano com contexto
- RF4 — registrar decisão e probabilidade de cada caso, para auditoria
- RF5 — permitir ao supervisor marcar uma decisão como incorreta
- RF6 — apresentar painel com a fila priorizada por risco

Requisitos não funcionais:

- RNF1 — executar dentro do free tier da Google Cloud Platform
- RNF2 — ingestão incremental: processar apenas o lote novo, sem duplicar registros
- RNF3 — reprodutibilidade: mesma semente, mesmo resultado
- RNF4 — nenhum dado pessoal na base ou nos artefatos
- RNF5 — código versionado, incluindo o da pipeline de dados
- RNF6 — nenhuma variável indisponível no momento em que a decisão é tomada

8.5 Onde cortar: uma decisão de produto, não de estatística

O modelo devolve uma probabilidade contínua. Onde colocar o corte que separa seguir no bot de encaminhar ao humano é decisão de produto, e não depende do modelo: depende de quanto volume a equipe humana consegue absorver. A calibração tem três passos — ordenar as conversas pela probabilidade de falha, descer a lista até o volume diário que a operação comporta, e adotar como corte a probabilidade nesse ponto.

Um corte agressivo demais entope a fila humana; um conservador demais faz o modelo não mudar nada. O parâmetro deve ser revisto sempre que a capacidade da operação mudar, e nesta entrega será fixado apenas para fins de demonstração.

8.6 Fora de escopo desta entrega

- Integração com o bot em produção. Tempo real, aqui, significa o caminho de inferência demonstrado de ponta a ponta em uma conversa, e não um serviço implantado
- Streaming por Pub/Sub, que permanece no desenho como evolução declarada
- Retreino automático: o ciclo é desenhado e o gatilho definido, mas a execução automática fica para depois
- Geração de resposta. O produto decide a rota, não escreve o texto

9. ARQUITETURA DO CICLO DE APRENDIZADO

9.1 O que faltava no desenho

A arquitetura desenhada na Sprint 1 descreve corretamente um pipeline analítico: o dado entra pela ingestão, atravessa as camadas e sai no dashboard. É um fluxo de mão única, e é por isso que a avaliação da Sprint 2 não encontrou nele o objetivo final do projeto.

Um pipeline analítico produz relatórios. O que este projeto constrói é um sistema que melhora com o uso, e isso exige um caminho de retorno que não estava desenhado: conversas novas geram rotulagem, que alimenta o retreino, que produz um modelo melhor, que influencia o atendimento seguinte, que vira conversa nova.

9.2 Os cinco estágios

Estágio	O que faz	Situação nesta entrega
1. Ingestão incremental	Cloud Scheduler dispara um Cloud Run Job que carrega apenas o lote novo	A construir
2. Camadas bronze, silver e gold	Tipagem, deduplicação e views de consumo	Implementado
3. Rotulagem	Rótulo operacional mais revisão humana amostral, que corrige o modelo	Desenhado; demonstrado com os rótulos existentes
4. Treino	Treino sobre a base rotulada, avaliação contra o modelo em produção e registro de versão	Versão inicial construída
5. Inferência e retorno	Triagem na abertura e painel do supervisor; o atendimento resultante volta a ser dado de entrada	Em lote nesta entrega




Figura 1 — O ciclo de aprendizado da Kenzie 360, com os serviços de cada estágio. A seta em destaque é o caminho de retorno que distingue um sistema que aprende de um pipeline analítico.

O estágio 3 é o que não existia em nenhum desenho anterior, e é a peça de maior valor para a aplicação em operação real. Um modelo sem processo de rotulagem funciona no dia da entrega e degrada em silêncio depois.

9.3 A ingestão incremental está mais próxima do que parecia

A auditoria da camada de dados encontrou que a silver **já está pronta para carga incremental**: ela deduplica por chave de negócio, com prevalência da ingestão mais recente. Se o mesmo registro entrar duas vezes, a versão nova prevalece e a antiga é descartada.

O único bloqueio está na bronze, que carrega em modo de substituição total. Trocar para modo incremental, mantendo o particionamento e as colunas de procedência que já existem, converte a pipeline atual sem reescrever a silver nem a gold. Para demonstrar o ciclo sem gerar base nova, a última semana do período é retida e carregada separadamente, como se fosse o lote que chegou depois.

10. AUDITORIA DO GERADOR E REVISÃO DA ANÁLISE

10.1 Por que auditar antes de modelar

Antes de escolher a variável-alvo do modelo, o gerador da base sintética foi auditado. A motivação era prática: em base sintética, é o gerador — e não a análise — que determina o que pode ser aprendido. Um alvo cuja regra a própria equipe escreveu produz acurácia alta e valor probatório nulo.

A auditoria encontrou o que se buscava, e também o que não se buscava: um erro na análise exploratória apresentada na Sprint 2.

10.2 O erro de denominador

A seção 6.5 calculava a taxa de falha do encaminhamento sobre as conversas com área registrada. No gerador, o caso resolvido registra a área em apenas 40% das vezes, enquanto o caso não resolvido a registra sempre. O denominador excluía três em cada cinco sucessos e nenhum fracasso, e a inflação era de exatamente 2,01 vezes.

Indicador	Publicado	Correto
Não resolução no atendimento humano	32,0%	15,9%
Resolução por área interna	64,0% a 69,6%	81,7% a 88,5%
Satisfação por área interna	3,29 a 3,54	3,74 a 3,90

Duas conclusões caíram junto. A afirmação de que Cartões seria a área de pior desempenho era ruído estatístico: 2,41 desvios-padrão em nove comparações simultâneas, exatamente o que o acaso produz. E a tese dos dois modos de falha era artefato, porque o motivo de transferência só é atribuído quando um atendente humano assume o caso — de modo que as conversas sem motivo que foram atendidas são, por construção, apenas as resolvidas.

Os eixos (a) e (b) da hipótese não foram afetados. O custo anual recalculado deu 11.197 horas contra as 11.106 publicadas, diferença de 0,8% e dentro do arredondamento.

10.3 O reposicionamento do atrito acumulado

A mesma auditoria mostrou que o efeito da recorrência não é um achado da análise: é um parâmetro deliberadamente introduzido na recalibração da base, com queda de 7% na resolução a cada contato prévio e 18% adicionais quando a conversa é reabertura.

A estrutura continua defensável — a alternativa, um modelo em que reincidir não muda nada, é claramente falsa sobre qualquer operação real, e os níveis agregados permanecem ancorados nos indicadores da operação. O que mudou foi o enquadramento: a seção passou a declarar os parâmetros e a apresentar os números como dimensionamento de uma premissa, e não como descoberta. A recomendação prática sobrevive independentemente da magnitude: o histórico de contatos precisa estar disponível na abertura da conversa.

10.4 Três parâmetros recuperados às cegas

A correção foi validada de forma independente. O cálculo refeito recuperou três constantes conhecidas do gerador, por caminhos que não se comunicam entre si:

Constante no gerador	Medido pela análise corrigida
Resolução pelo atendimento humano: 0,84	84,09%
Motivo de transferência: sorteio uniforme entre cinco, 0,20	20,0%
Desistência na fila: 0,10	9,84%

Os números por área foram obtidos duas vezes, uma por consulta SQL sobre o data warehouse e outra por processamento local do arquivo de origem, com resultados idênticos nas nove áreas. Quando dois caminhos independentes chegam ao mesmo valor, o cálculo está correto.

10.5 O que a base permite e não permite afirmar sobre as áreas

Medidas corretamente, as nove áreas internas resolvem em torno de 84% e nenhuma se distingue das demais. Isso não é evidência de que sejam equivalentes na operação real: o gerador atribui a todas a mesma probabilidade de resolução, e a uniformidade observada é decisão de modelagem, não achado empírico.

Numa operação real a expectativa é a oposta. Áreas com dependência de terceiros, restrição regulatória ou sem permissão de escrita nos sistemas de origem tendem a devolver mais casos. Testar isso exige que a área de destino seja registrada em todos os encaminhamentos, e não apenas quando o caso dá errado. Esse é um requisito de captura de dado que fica registrado para a V2.

Pelo mesmo método testou-se se as filas perdem clientes em proporções diferentes antes do atendimento. Não perdem: qui-quadrado de 14,86 com oito graus de liberdade e p de 0,062, com o maior desvio individual em 2,00 sigma contra os 2,1 esperados para o máximo de nove sorteios. O resultado negativo é registrado por ser instrutivo — um valor de p nessa faixa é exatamente o que tenta a leitura apressada.

11. MODELAGEM PREDITIVA — VERSÃO INICIAL

11.1 A escolha do alvo

Os candidatos foram testados diretamente na base antes de qualquer treino, medindo o teto de desempenho de cada um. A classificação do motivo de transferência mostrou-se **inviável**: o campo é atribuído por sorteio uniforme no gerador, sem vínculo com texto, assunto ou cliente. Os cinco motivos aparecem entre 19,4% e 20,5%, e cada um se distribui pelas nove áreas na mesma proporção, o que limita qualquer modelo a 20% de acurácia — o acaso.

A previsão de descadastro foi descartada por decorrer de regra determinística do próprio gerador, e a classificação do tipo de demanda por circularidade com a categoria.

A opção adotada é um pipeline de dois estágios. O primeiro classifica a intenção, derivando do texto de abertura a categoria da demanda e, por mapeamento determinístico, a área de encaminhamento. O segundo estima a probabilidade de o bot resolver o caso, a partir da categoria prevista e do histórico do cliente. Um alimenta o outro, e juntos constituem a triagem na abertura.

11.2 Tetos medidos antes do treino

Medir o teto antes de treinar é o que permite ler o resultado com honestidade:

Estágio e métrica	Baseline	Teto
Estágio 1 — acurácia	14,48%	100,00%
Estágio 2 — acurácia	74,77%	76,88%
Estágio 2 — AUC	0,500	0,750

O teto de 100% do estágio 1 decorre de nenhuma das 11.438 aberturas distintas aparecer em mais de uma categoria. Já o estágio 2, como classificador, supera o baseline em apenas 2,1 pontos percentuais e é praticamente inútil nesse formato; como escore de risco, ordena conversas por probabilidade de falha com um teto que significa alguma coisa. **O resultado do projeto é o AUC do estágio 2 contra 0,750, e não a acurácia do estágio 1.**

11.3 Estágio 1: resultado

Métrica	Valor
Baseline (prever sempre a classe majoritária)	14,48%
Acurácia	99,99%
F1 macro	99,93%
Teto do problema	100,00%
Acurácia do roteamento (categoria para área)	99,99%

O conjunto foi dividido por cliente, e não por conversa, porque contatos prévios e reabertura ligam as conversas de um mesmo cliente: dividir por conversa faria o mesmo cliente aparecer nos dois lados, e o modelo memorizaria trajetórias em vez de aprender padrões. Foram 25.415 conversas de treino e 8.383 de teste, com interseção de clientes verificada em zero antes do treino.

Houve **um erro em 8.383 casos** — uma conversa de operações de pessoa jurídica classificada como câmbio. Esse segmento representa 0,6% da base e possui aberturas próprias. O erro isolado é a evidência de que o modelo generaliza em vez de decorar: um resultado de 100,00% cravado indicaria uma tabela de consulta.

A representação de texto usa n-gramas de caractere, e não de palavra, escolha ditada pela base: três idiomas, abreviações, erros de digitação injetados deliberadamente e alternância entre português e inglês nos clientes expatriados.

11.4 Controle de vazamento

A tabela de atendimentos possui trinta colunas, e a maioria só existe depois que a conversa terminou. Satisfação, duração, número de mensagens e status são consequência do desfecho; um modelo que as utilizasse alcançaria desempenho excelente e inútil, já que no momento da decisão nenhuma delas existe.

O script de treino carrega uma lista de dezoito colunas proibidas e **interrompe a execução** se alguma delas entrar no conjunto de variáveis. A regra que a define é simples: uma variável só é legítima se seu valor estiver disponível no instante em que o modelo precisa decidir. Está registrado também que, no estágio 2, a categoria deve entrar como valor previsto pelo estágio 1, e não como valor verdadeiro, porque em produção só existe a previsão.

11.5 Limitação declarada

A base é sintética e calibrada por indicadores agregados da operação real. **Um modelo treinado sobre texto sintético aprende os padrões do gerador, não os do cliente.** O que esta entrega demonstra com solidez é que o processo funciona de ponta a ponta — ingestão, rotulagem, treino, inferência e retorno. É o processo, e não o modelo treinado, que transfere para a operação real.

12. PRÓXIMOS PASSOS

- Construir o estágio 2 do modelo e reportar o AUC obtido contra o teto de 0,750
- Converter a carga da bronze para modo incremental e agendá-la
- Versionar o código da pipeline de dados em repositório próprio, estendendo a ele o padrão de promoção por Pull Request já em operação na infraestrutura
- Publicar o painel de resultados com a saída do modelo
- Consolidar a documentação e preparar a apresentação final