

BRIEFING DO PROJETO INTEGRADOR

Disciplina: Hands-On Fundamentos de Dados e Analytics

Módulo 1 – MBA em Engenharia de Dados – Universidade Presbiteriana Mackenzie

Mentoria: Prof. Gustavo Ferreira

Sprint 2 — Seções 5 a 7 • Projeto Kenzie 360

Este documento dá continuidade ao Briefing da Sprint 1 (seções 1 a 4). As seções abaixo cobrem a implementação do Data Lake, a análise exploratória e a governança, correspondendo aos entregáveis da Sprint 2.

5. ARQUITETURA E IMPLEMENTAÇÃO DO DATA LAKE

5.1 Da arquitetura lógica à implementação

A Sprint 1 desenhou a arquitetura Lambda na GCP, mapeando as camadas Batch, Speed e Serving ao modelo RAW → TRUSTED → CURATED. A Sprint 2 implementou esse desenho no BigQuery.

Camada do Lake	Implementação	Papel
RAW (bronze)	kenzie360_bronze	Registro imutável da origem, tudo em STRING, com rastreabilidade
TRUSTED (silver)	kenzie360_silver	Tipado, deduplicado, particionado, PII tratada
CURATED (gold)	kenzie360_gold	9 views e 1 dimensão, cada uma justificada por um achado

O bucket gs://kenzie360-raw-ids26 no Cloud Storage guarda os arquivos originais antes da ingestão, versionados por data. Projeto GCP: kenzie-360-mba, região us-central1.

5.2 Decisões técnicas e suas justificativas

As decisões abaixo foram tomadas a partir da inspeção da base, não por convenção.

Decisão	Escolha	Por quê
Tipo de data_hora	DATETIME	A origem não declara fuso horário. Converter para UTC seria inventar informação
Campo resolvida	STRING	Tem 4 valores (Sim/Não/Desconhecido/Não aplicável). Tratar como booleano perderia a distinção entre 'não resolveu' e 'não se aplica'
Particionamento	Por data_ref (DATE)	Sem partição, cada consulta varreria as 405 mil mensagens inteiras
Clustering	segmento, categoria, idioma	São exatamente os filtros mais usados na análise e no dashboard
Camada gold	Views, não tabelas	Não ocupam armazenamento e nunca ficam defasadas
Conversões	SAFE_CAST	Valor inesperado vira NULL e aparece na validação, em vez de quebrar a carga

5.3 O detalhe que quase corrompeu a ingestão

A inspeção da base encontrou 4.361 linhas na tabela de atendimentos e 4.842 na de mensagens contendo ponto e vírgula dentro de campos de texto — o mesmo caractere usado como separador do arquivo.

Exemplo real: "Encaminhei para a área de Mesa de Limites; retornaremos em até 48h."

Esses campos vêm corretamente protegidos por aspas duplas, e a prova é que o número de linhas com aspas coincide exatamente com o de linhas com campo extra. A carga só funciona porque declara o caractere de aspas explicitamente. Sem isso, os registros quebrariam em colunas adicionais sem gerar erro — corrupção silenciosa.

5.4 Modelagem dimensional para consumo analítico

Além das três camadas do Lake, foram implementados os dois modelos de consumo previstos nos entregáveis da disciplina, ambos na camada CURATED.

Star Schema — modelo estrela com grão de um atendimento, composto por uma tabela fato e seis dimensões conformes:

Objeto	Registros	Conteúdo
fato_atendimento	36.000	Grão de um atendimento. Métricas, flags e as seis chaves estrangeiras. Particionada por data e clusterizada
dim_tempo	182	Calendário completo, inclusive dias sem movimento, para séries temporais sem lacunas
dim_cliente	15.001	Perfil e métricas de relacionamento: recorrência, primeiro e último contato, faixa de recorrência
dim_assunto	13	Categoria, produto e a classificação por tipo de ação exigida
dim_canal	9	Canal de entrada, canal humano e origem do contato
dim_desfecho	11	Status, cluster de satisfação e modo de falha
dim_motivo_transferencia	47	Motivo, área de encaminhamento e natureza da limitação

As dimensões carregam a inteligência da análise, e não apenas rótulos. A dimensão de assunto já traz o tipo de demanda — informacional, misto ou transacional — que foi o corte revelador da causa do problema. A de desfecho já traz o cluster de satisfação, porque a análise mostrou que o CSAT é bimodal. A de motivo classifica a natureza da limitação: falta de permissão transacional ou necessidade de julgamento humano. Isso evita que cada consulta recalcule as mesmas regras de negócio.

Cada dimensão possui um membro "não aplicável" com chave zero, garantindo que nenhuma linha da fato fique órfã. A validação automática confirmou integridade referencial completa: zero órfãs nas seis dimensões.

Wide Table — a view `vw_wide_atendimento` entrega o mesmo modelo já desnormalizado, com todas as dimensões resolvidas numa única linha por atendimento. Dispensa junções para treino de modelos e

exploração rápida, e é também o caminho mais direto para conectar o Looker Studio, por não exigir configuração de relacionamentos.

Chaves substitutas: geradas por função de hash sobre a chave natural, e não por sequência numérica. A consequência é que recarregar a base produz exatamente as mesmas chaves — o modelo dimensional é tão reproduzível quanto o restante da pipeline.

5.5 Reprodutibilidade

Todo o ambiente é recriável a partir dos scripts que acompanham esta entrega, e cada script valida o próprio resultado, abortando se a contagem divergir do esperado:

- gerar_dataset_cde_v8.py — gera a base (SEED = 42, determinístico)
- 01_carga_bronze.py — envia ao Cloud Storage e carrega a camada bronze
- 02_cria_silver.py — executa o DDL da silver com validação
- 06_cria_gold.py — cria e valida as views da gold
- 05_inventario_bq.py — inventário com checagem de duplicação

Os DDLs ficam versionados em arquivos .sql separados do código Python que os executa, permitindo revisão do SQL sem leitura de código.

6. ANÁLISE EXPLORATÓRIA DE DADOS E MÉTRICAS

6.1 Metodologia

A análise foi conduzida em 22 consultas SQL versionadas sobre a camada silver — 16 exploratórias e 6 de teste direto da hipótese do projeto. Cada consulta grava seu resultado em arquivo próprio, permitindo auditoria independente dos números apresentados.

6.2 A hipótese e o veredito

O projeto parte de uma tese sobre por que a Kenzie V1 não entrega:

(a) O script do bot não resolve por conta própria — sabe informar, não sabe executar. **(b)** Por isso a operação depende cronicamente do atendimento humano. **(c)** E o próprio atendimento humano falha, porque a demanda circula entre áreas internas do banco.

Os três eixos foram testados separadamente e todos se confirmaram.

Eixo	Veredito	Evidência central
(a)	Confirmado	A resolução pelo bot cai de 45,9% em demandas informacionais para 20,9% em transacionais. E 47,7% de toda a demanda é transacional
(b)	Confirmado	11.106 horas humanas por ano (6,3 postos em tempo integral) para uma autonomia de apenas 25,2%
(c)	Confirmado	Das 6.744 demandas encaminhadas a áreas internas, 32,0% voltam sem solução — e as nove áreas falham na mesma proporção

6.3 O problema não é linguagem, é permissão

Reclassificando as demandas pelo tipo de ação que exigem — e não pelo assunto — o padrão aparece com nitidez:

Tipo de demanda	% do total	Bot resolve	Pede humano	CSAT
Informacional (só consultar)	18,4%	45,9%	37,0%	3,87
Misto (consulta + ação leve)	20,1%	33,8%	45,0%	3,76
Transacional (exige sistema)	47,7%	20,9%	54,4%	3,65

Quatro indicadores se movem juntos e na mesma direção. A Kenzie entende o pedido — o que ela não tem é permissão de escrita nos sistemas do banco. Desbloquear um PIX, aprovar um documento ou alterar um limite exige executar uma transação, e o bot só sabe devolver texto.

Consequência para a V2: o ganho de automação não virá de treinar melhor o modelo de linguagem, e sim de conceder ao bot acesso transacional aos sistemas internos, com as travas de segurança correspondentes. É decisão de arquitetura e de apetite a risco, não de processamento de linguagem.

6.4 O custo da dependência

O bot resolve em 5,2 minutos, contra 24,6 do atendimento humano — e com satisfação maior (CSAT 4,34 contra 4,19). Não existe, nesta operação, o trade-off clássico entre custo e qualidade: automatizar melhora os dois.

Cenário de autonomia do bot	Ganho anual	Equivalente
+10 pontos percentuais	2.328 horas	1,3 FTE
Chegar a 40%	3.445 horas	2,0 FTE
Chegar a 50%	5.773 horas	3,3 FTE
Chegar a 60%	8.101 horas	4,6 FTE

Este é o business case da V2 em uma linha: cada 10 pontos percentuais de autonomia devolvem 1,3 posto de atendimento em tempo integral. E, pelo eixo (a), sabe-se exatamente onde esses pontos estão — nos 47,7% de demanda transacional hoje bloqueada.

6.5 Os dois modos de falha do encaminhamento

A investigação do eixo (c) revelou que existem duas falhas de natureza oposta, e confundi-las leva à ação errada:

Caminho	Volume	O que acontece
Sem motivo classificado	8.304 (55,2%)	17,8% nunca são atendidas. Mas quando são, resolvem em 100% dos casos — o problema é de roteamento
Com motivo classificado	6.744 (44,8%)	100% são atendidas. Mas 32,0% voltam sem solução — o problema é de capacidade de resolução

Juntas, as duas falhas somam 3.639 conversas (10,1% da operação) que consumiram atendimento e não entregaram resultado.

Quanto à segunda falha, nenhuma área é a culpada: as nove áreas internas resolvem entre 64,0% e 69,6% do que recebem. Quando o desempenho é uniformemente insatisfatório, a causa não está em nenhuma equipe — está no desenho do processo de encaminhamento. A leitura mais plausível é que a demanda chega à área sem o contexto necessário para ser resolvida de uma vez.

6.6 Demais achados relevantes

Achado	Evidência
A satisfação é bimodal	Quem tem o problema resolvido dá entre 3,94 e 4,34; quem não tem, entre 1,75 e 1,87. Não há nenhum desfecho no intervalo. A média de 3,74 é artefato aritmético e não descreve nenhum cliente
A espiral de recorrência	A resolução cai de 29,9% no primeiro contato para 15,4% a partir do quinto, enquanto a insatisfação sobe de 22,0% para 36,6%
Não há barreira de idioma	Dentro do segmento CDE, a variação entre português, inglês e espanhol é de 0,5 ponto percentual
Vale de frustração no meio da conversa	54,5% das falas do terceiro quinto são negativas; o humor só melhora no trecho final
Bloqueio de TED/PIX é a pior dor	14,3% de resolução pelo bot, 58,9% de transferência e a maior duração média

Sobre a ausência de barreira de idioma: este resultado refuta uma hipótese inicial da própria equipe e foi mantido no relatório porque elimina a explicação concorrente mais fácil. A Kenzie atende igualmente mal em três idiomas e nos dois segmentos, o que reforça que a causa é estrutural. O que de fato distingue o cliente CDE é o produto: câmbio, praticamente exclusivo desse público, é demanda transacional pura.

6.7 Um alerta metodológico: composição versus desempenho

Consultando o modelo dimensional, observa-se que, entre as demandas informacionais, o bot resolve 42,5% dos atendimentos de clientes CDE contra 53,6% dos correntistas nacionais — onze pontos percentuais de diferença no tipo de demanda mais simples. À primeira vista, isso contradiz o achado de que não há penalização do público CDE.

A diferença, porém, é integralmente explicada pela composição do grupo, e não por qualidade de atendimento:

Categoria dentro de Informacional	% no CDE	% no Nacional	Bot resolve
Termos e Documentação BR	47,6%	8,0%	29,3%
Investimentos CDB	28,6%	52,0%	49,4%
Saldo e Extrato	23,8%	40,0%	61,1%

Aplicando essas proporções às taxas de cada categoria, a resolução esperada é de 42,9% para o CDE e 52,4% para o nacional — praticamente idêntica à observada. O bot atende os dois públicos com a mesma eficácia dentro de cada categoria; o que difere é a distribuição das perguntas.

O achado de negócio: quase metade das dúvidas informacionais do cliente CDE são sobre termos e documentação brasileira — o que é CPF, como funciona o PIX, se o CPF continua válido morando fora. São perguntas de quem não convive com o sistema financeiro brasileiro, e é justamente a categoria informacional com menor resolução. Não se trata de uma limitação de capacidade do bot, e sim de uma lacuna de conteúdo específica desse público, resolvível com material explicativo dedicado.

Este caso ilustra por que a análise agregada exige cuidado: comparar dois grupos com composições diferentes produz conclusões enganosas. O modelo dimensional permitiu identificar e quantificar o efeito.

6.8 Recalibração da base a partir dos achados

A análise exploratória identificou cinco limitações no próprio gerador da base sintética. Três foram corrigidas em uma nova versão:

Limitação	Problema	Correção
Sazonalidade	Volume diário plano (variação de 7,7%); segunda-feira igual a domingo	Efeito de dia da semana, vencimento de fatura, tendência e picos de incidente. Variação passou a 30,6%
Fuso horário	90% do volume entre 8h e 19h de Brasília, embora 70% da base resida no exterior	Cada cliente CDE recebe um fuso, e seu horário comercial local é convertido para o de Brasília
Atrito acumulado	Ser reabertura não alterava o desfecho: o cliente na quarta tentativa era tratado como se fosse a primeira	Contatos prévios e reabertura passam a reduzir a resolução e elevar abandono e insatisfação

A recalibração preservou os níveis agregados calibrados com a operação real — resolução pelo bot 25,2%, transferência 41,8%, abandono 17,3%, CSAT 3,74, com desvio máximo de 0,3 ponto percentual. O que mudou foi a distribuição interna, não os totais. O schema permaneceu idêntico, e a pipeline absorveu a mudança sem alteração de código.

7. GOVERNANÇA, INTEGRAÇÃO CONTÍNUA E INFRAESTRUTURA COMO CÓDIGO

7.1 Governança de dados

O controle de acesso segue o princípio de menor privilégio, com papéis específicos em vez do papel genérico de Editor:

Camada	Quem acessa	Papel atribuído
bronze	Esteira de ingestão	BigQuery Data Editor
silver	Engenharia de dados	BigQuery Data Editor

Camada	Quem acessa	Papel atribuído
gold	Analistas e Looker Studio	BigQuery Data Viewer

Rastreabilidade: as colunas `_ingestion_ts` e `_source_file` acompanham cada registro da bronze até a silver, permitindo responder de onde veio e quando entrou qualquer linha da base.

Versionamento de dados: a promoção de uma nova versão da base preserva a anterior em tabelas com sufixo próprio, nos dois datasets. Ambas permanecem consultáveis e comparáveis em SQL.

LGPD: a base é 100% sintética e nenhum dado pessoal foi utilizado. Ainda assim, o pipeline de mascaramento está implementado na transição bronze → silver, aplicando expressões regulares para e-mail e CPF e registrando em coluna própria quando a regra atuou. Telefone ficou deliberadamente de fora: o padrão colide com valores monetários e números de protocolo, e um falso positivo destruiria dado legítimo. Na base atual a regra não encontra ocorrências — os dados já nascem mascarados por construção — mas ela permanece porque em produção a origem é um export real, onde essa garantia não existe.

A bronze preserva o texto como veio e é a camada de acesso mais restrito; a silver entrega a versão tratada. Quem consulta a silver não precisa ver o original.

7.2 Integração contínua e infraestrutura como código

A entrega separa três trilhas de pipeline independentes que compartilham a mesma base de infraestrutura como código, evitando que uma mudança no modelo force o redeploy de toda a infraestrutura:

Trilha	O que entrega	Situação
Infraestrutura (Terraform)	Buckets, datasets, IAM e políticas de acesso	Implementada e em operação
Pipeline de dados	Cargas e transformações bronze → silver → gold	Scripts versionados; esteira prevista
Pipeline de ML	Treino, avaliação e publicação do modelo de NLP	Prevista; depende da definição do alvo

Repositório: <https://github.com/MACK-Hand-on/MACK> — público. O histórico de revisão, o Pull Request com o plano do Terraform publicado como comentário e as execuções da esteira ficam visíveis na aba Actions.

A trilha de infraestrutura foi implementada e exercitada de ponta a ponta. Nenhuma alteração de infraestrutura chega ao ambiente sem passar por quatro controles encadeados:

Etapa	Controle aplicado
Abertura do Pull Request	Verificação automática de formatação, sintaxe, boas práticas de GCP (tflint) e segurança (checkov)
Revisão	O plano de execução do Terraform é publicado como comentário no próprio

Etapa	Controle aplicado
	PR, legível por quem não domina a ferramenta
Merge	A branch principal exige Pull Request aprovado por outra pessoa; escrita direta, reescrita de histórico e exclusão estão bloqueadas
Aplicação	Parada obrigatória aguardando aprovação humana registrada, com o comentário do aprovador gravado no histórico

Autenticação: via Workload Identity Federation, sem chaves estáticas de conta de serviço armazenadas como segredos. O GCP confia em uma identidade emitida pelo GitHub para um repositório específico, e a autorização é dupla: uma condição no provedor restringe a organização de origem e um vínculo na conta de serviço restringe o repositório exato. Não existe arquivo de credencial que possa vaziar — decisão especialmente relevante em ambiente bancário, onde credenciais de longa duração representam risco desproporcional.

Adoção do ambiente existente: os recursos provisionados manualmente na fundação foram incorporados ao Terraform por importação, e não recriados. A alternativa — aplicar o código como estava — teria criado um segundo conjunto de recursos vazio ao lado do que contém os dados. O plano resultante foi lido três vezes antes da aplicação: localmente, como comentário no PR e na tela de aprovação. O resultado da execução foi de 4 recursos alterados e nenhum destruído, idêntico ao previsto.

Separação de responsabilidades: na execução registrada, quem revisou e mesclou o código e quem autorizou a alteração da infraestrutura foram pessoas distintas, em dois pontos de controle diferentes. A separação não foi combinada previamente — decorre do desenho da esteira, que é precisamente o objetivo de um controle automatizado.

7.3 O que a automação encontrou

O argumento a favor de uma esteira de verificação costuma ser apresentado como boas práticas. Neste projeto ele pôde ser verificado: a automação expôs três problemas reais que a revisão humana não havia detectado.

Achado	Como apareceu e o que significava
Módulo sem declaração de dependências	O tfint apontou, na primeira execução, que o módulo de data lake não declarava versão do Terraform nem do provedor. O módulo funcionava por herdar a configuração de quem o chamava — uma dependência implícita, que quebraria de forma silenciosa se reutilizado em outro contexto. O achado passou por duas revisões humanas antes de a ferramenta encontrá-lo em fração de segundo.
Bucket de dados crus sem proteção contra exposição pública	O plano do Terraform revelou que a política do bucket estava como herdada, e não imposta. A aplicação a corrigiu para imposta, além de ligar o versionamento de objetos. A infraestrutura como código não apenas documentou o ambiente: corrigiu uma lacuna de segurança que existia no provisionamento manual.
Ambiente de aprovação sem regra de proteção	O GitHub cria automaticamente qualquer ambiente citado em um fluxo de trabalho, sem nenhuma regra associada. O ambiente de produção existia nessa condição: aparentava ser um portão de aprovação e não era. Só foi detectado ao consultar suas regras por API, e não pela interface, que exibe o ambiente como existente.

Os três achados têm a mesma natureza: são controles que existiam no papel e não no sistema. Nenhum apareceria em teste funcional, porque nada estava quebrado — apenas desprotegido.

Uma dependência documentada que se materializou: o registro técnico do projeto anotou que transferir o repositório de propriedade invalidaria a configuração de autenticação, e que o ajuste precisaria acompanhar a transferência. Doze horas depois o repositório foi transferido para uma organização. A correção estava escrita e levou dois comandos, sem migração e sem perda de dado. Sem o registro, o sintoma seguinte teria sido uma falha genérica de permissão, sem nenhuma alteração de código que a explicasse.

7.4 Adequação da proposta ao orçamento do projeto

A proposta original de arquitetura foi revista para caber no Free Tier da GCP, mantendo o desenho conceitual e substituindo serviços cujo custo inviabilizaria o projeto acadêmico:

Serviço proposto	Restrição	Substituição adotada
Cloud Composer	Sem free tier; custo aproximado de US\$ 525 por mês em operação contínua	Cloud Scheduler com Cloud Run Jobs, ou consultas agendadas do BigQuery
Dataflow (streaming)	Cobrança por worker-hora mesmo ocioso	Assinatura do Pub/Sub que grava diretamente no BigQuery
DLP API	Serviço pago	Mascaramento por expressão regular em SQL, já implementado
Dataplex	Complexidade e custo desproporcionais ao escopo	Policy tags e segurança em nível de coluna, nativos do BigQuery

O Cloud Composer permanece documentado como arquitetura alvo para um ambiente bancário de produção, com o trade-off de custo explicitado. A escolha é consciente, não uma limitação técnica.

Nota sobre o bootstrap: a fundação do ambiente — projeto, APIs e o bucket que guarda o estado do próprio Terraform — foi provisionada manualmente. Fazer o Terraform criar o bucket onde guarda seu estado configuraria uma dependência circular; a separação entre bootstrap manual e recursos versionados é a prática padrão. Os demais recursos, antes provisionados à mão, passaram ao controle do Terraform por importação.

7.5 Custo efetivo do ambiente

Recurso	Consumo	Franquia mensal	Uso
Armazenamento no BigQuery	0,543 GiB	10 GiB	5,4%
Consultas processadas	380 MB	1 TiB	0,04%

Alerta de orçamento configurado em US\$ 20 mensais, com avisos em 10%, 50% e 90% do limite.

7.6 Próximos passos

- Publicar o protótipo do dashboard executivo no Looker Studio

- Definir, em conjunto, a variável-alvo do modelo preditivo/classificatório de NLP
- Versionar o código da pipeline de dados em repositório próprio, estendendo a ele o mesmo padrão de promoção por Pull Request já em operação na infraestrutura
- Atualizar as ações da esteira que ainda declaram a versão do Node.js em processo de descontinuação pelo GitHub

Quanto ao segundo item, a análise exploratória ordenou as opções sem decidir por elas. São favorecidas pelos dados: a classificação do motivo de transferência (55,2% das transferências saem sem motivo registrado, e é delas que vem a fila abandonada) e a previsão de descadastro (que ocorre exclusivamente entre clientes de sentimento inicial negativo). É desfavorecida a previsão de resolução a partir do sentimento inicial isolado, cujo poder preditivo se mostrou fraco.