

MBA ENGENHARIA DE DADOS • UNIVERSIDADE PRESBITERIANA MACKENZIE • 2026

Kenzie 360

Dar memória e capacidade de decisão à assistente virtual de um banco

Atendimento a clientes CDE — Conta de Domiciliado no Exterior, não residentes

Ilan David Schapira • Giovanna Caetano Protti • Jonathas Borges

Orientação: Prof. Gustavo Ferreira

Três pessoas, três frentes

ILAN

Negócio, produto e modelagem

Definiu a pergunta do modelo, treinou e defendeu os números. Vem de Economia e de produto bancário — não de tecnologia.

GIOVANNA

Análise, painel e qualidade

Fez a análise exploratória e o painel no Looker Studio. Virou o controle de qualidade do grupo: “número que não rodamos é número que não defendemos”.

JONATHAS

Plataforma e automação

Construiu o data lake no Google Cloud por código e a esteira que publica tudo com aprovação humana.

EM PALAVRAS SIMPLES

Ninguém ficou só na sua especialidade — e os três erros graves que corrigimos no projeto nasceram justamente nas fronteiras entre as frentes, nunca dentro de uma delas.

Usamos IA para escrever a maior parte do código. O que ficou com a gente: escolher a pergunta, desconfiar do resultado e declarar os limites.

A Kenzie sabe informar. Não sabe resolver.

Três medições, no semestre de fevereiro a agosto — 36.000 conversas e 405.073 mensagens.

25,2%

**é tudo que a Kenzie
resolve sozinha**

Quando o assunto é informação — saldo, taxa, horário — ela resolve 45,9%. Quando o cliente pede uma ação — desbloquear um PIX, subir um limite — cai para 20,9%. E a ação é 47,7% de tudo que chega.

15,9%

**dos casos que chegam
ao humano também falham**

O problema não é só do bot. E as nove áreas internas falham na mesma proporção — o que aponta para o processo, não para uma equipe específica.


8.391

**conversas não chegam
a ninguém**

O cliente desiste em 4,4 minutos, antes de qualquer atendente. São 27% de toda a demanda — invisíveis em qualquer relatório de atendimento, porque nunca abriram um ticket.

Os 15,9% eram 32,0% na nossa primeira versão: o denominador estava errado e excluía três em cada cinco casos resolvidos. Corrigimos e retratamos duas conclusões que dependiam dele.

E está piorando mês a mês



O QUE O GRÁFICO MOSTRA

30,9% → 22,5%

A Kenzie resolve cada vez menos, e nada no bot mudou nesse período.

A explicação é o desgaste do cliente: no começo da série quase todo mundo é primeiro contato. Com os meses, a carteira acumula quem já tentou e voltou — e quem volta é atendido pior.

A linha de cima cai menos: o humano está absorvendo a queda do bot.

EM PALAVRAS SIMPLES

Sem memória, o problema se acumula: cada retorno do cliente piora o atendimento seguinte, e o custo disso vai todo para a fila do humano.

Três mudanças, nenhuma delas “trocar o bot”

1 Dar memória

Hoje a Kenzie não sabe que este cliente já voltou quatro vezes pelo mesmo motivo. Guardar o histórico por cliente é a base de tudo o que vem depois.

2 Prever antes de falhar

No minuto zero da conversa, antes de qualquer tentativa, estimar a chance de a Kenzie não conseguir resolver — com o que já se sabe naquele momento.

3 Transformar a previsão em decisão

Uma nota que ninguém usa não vale nada. A nota entra na operação como ordem de fila: quem fica com o bot, quem vai para observação, quem vai direto ao humano.

O QUE DELIBERADAMENTE FICOU FORA

Trocar a Kenzie por outro bot · contratar mais atendentes · prometer que o bot passe a executar o que hoje não executa

EM PALAVRAS SIMPLES

A proposta não pede investimento novo: pede que a mesma fila, com as mesmas pessoas, seja atendida na ordem certa.

Onde o dado mora



POR BAIXO DE TUDO

Terraform e GitHub Actions: nada foi clicado no console. Toda mudança passa por validar → simular → aprovação humana → aplicar, e a nuvem é reconstruível do zero a partir do repositório. Sem senha guardada em lugar nenhum.

EM PALAVRAS SIMPLES

É o mesmo princípio de um processo bancário: o documento original fica intacto, cada tratamento vira uma cópia nova, e sempre se sabe quem mexeu e quando.

Como o dado é cuidado

Os quatro controles que o escopo do MBA pede — e o que cada um faz na prática.

QUEM PODE VER

Cada etapa tem permissão própria: quem lê a camada limpa não tem acesso ao texto original da conversa.

E a esteira que publica não guarda nenhuma senha.

DE ONDE VEIO

Toda linha carrega o arquivo de origem e a data em que entrou.

Cada visão publicada tem escrita a pergunta que ela responde.

SE ESTÁ CERTO

O formato do arquivo é declarado antes da carga. Se a origem mudar, a carga falha e avisa — em vez de passar errado.

O modelo tem 18 colunas proibidas: se alguma entrar, o script aborta.

DADO PESSOAL

Nome, documento e telefone não existem em nenhuma camada: são mascarados antes de gravar.

A base é 100% sintética — nenhum cliente real foi usado.

O que prova que os controles funcionam não é a lista deles — são os seis erros que eles pegaram, incluindo duas conclusões que publicamos e depois retratamos.

A pergunta que o modelo responde

“Qual é a chance de a Kenzie não conseguir resolver esta conversa sozinha?”

QUANDO A CONTA É FEITA

No minuto zero.

A nota sai quando a conversa abre, antes de qualquer tentativa de atendimento. Se ela saísse depois, não daria para agir.

COM O QUE ELE DECIDE

13 informações.

Assunto, perfil do cliente, canal, horário, e — as que mais pesam — quantas vezes esse cliente já voltou e se o caso é uma reabertura.

O QUE SAI DISSO

Um número de 0 a 1.

0,20 é uma conversa que provavelmente se resolve sozinha. 0,85 é uma que provavelmente vai falhar. Fica gravado junto com a conversa.

ANTES DESTA, TÍNHAMOS OUTRO — E JOGAMOS FORA

Um classificador de intenção com 99,99% de acerto. Ele estava lendo o assunto num texto que o próprio sistema havia escrito a partir do assunto — descobria uma resposta que já estava na tabela. O número era real e não significava nada. A regra que ficou: **quando o modelo acerta quase tudo, desconfie da variável.**

Regressão logística: a escolha é pela auditoria

É o modelo mais simples da lista — e é essa a vantagem. Num banco, uma decisão que não se explica não pode ser usada.

A conta pode ser lida linha por linha

O modelo é uma soma de pesos, um por informação. Dá para dizer por que ESTA conversa recebeu 0,85 e não 0,60 — e qual pedaço da nota veio de qual informação. Um modelo mais moderno acerta parecido e não responde a essa pergunta.

Qualquer um refaz a conta, sem o nosso ambiente

Os 49 pesos do modelo estão publicados. O auditor não precisa do nosso código nem da nossa nuvem para conferir uma nota: a demonstração no fim desta apresentação roda a mesma conta dentro do navegador, sem servidor.

Mesmo dado, mesmo número, sempre

Nós reproduzimos o modelo em duas máquinas diferentes e chegamos ao mesmo resultado até a quarta casa decimal. A separação entre treino e teste é por cliente, com zero clientes em comum — o modelo não pode ter “decorado” ninguém.

Dá para provar o que ficou fora

18 colunas são proibidas por construção: informação que só existe depois do fim da conversa, e qualquer coisa que possa identificar a pessoa. Se uma delas entrar, o script para e acusa.

E NÃO CUSTOU DESEMPENHO


Testamos sete modelos mais complexos — random forest, árvores, gradient boosting, XGBoost. **Nenhum superou a regressão logística.** O limite não está no algoritmo: está na informação que existe no minuto zero. Então a caixa-preta traria custo de explicação sem ganho de acerto.

RESULTADOS

0 modelo acerta o quanto esta base permite acertar

A medida é o AUC: pegue duas conversas, uma que falhou e uma que deu certo — em 67 de cada 100 desses pares o modelo dá a nota maior à que falhou. Medido em 7.712 conversas que ele nunca viu, de clientes que não estavam no treino.

ENTRE O ACASO E O MÁXIMO QUE ESTA BASE PERMITE



99,6% do máximo possível. A distância entre o nosso modelo e o teto desta base é 0,0007.

POR QUE NÃO FALAMOS EM ACERTO

Chutando “não resolve” em toda conversa já se acerta 70,5%. O modelo acerta 72,8%. O ganho dele está em ordenar a fila, não em acertar mais.

COMO SABEMOS QUAL É O MÁXIMO

Nós escrevemos o gerador da base, então conhecemos a regra que sorteia o desfecho. O teto foi calculado antes de treinar — não é estimativa.

E OS MODELOS MAIS COMPLEXOS

Random forest: 0,6684. Árvores, gradient boosting e XGBoost: nenhum superou. O limite é a informação disponível, não o algoritmo.

A nota virando decisão de operação

BAIXO

nota abaixo de 0,65

26,9%

da fila

a Kenzie resolve 47,5%

→ deixar com a Kenzie

MÉDIO

de 0,65 a 0,80

40,2%

da fila

a Kenzie resolve 27,6%

→ fila de observação

ALTO

acima de 0,80

32,9%

da fila

a Kenzie resolve 17,1%

→ encaminhar agora

Os cortes não saíram da estatística: saíram da capacidade real medida na operação — 11,8 atendimentos por pessoa/dia, 74% de uso médio da equipe, 123% no pico.

73,1% da fila cai em Médio ou Alto — e a operação já encaminha 73,8% ao humano hoje.

EM PALAVRAS SIMPLES

O modelo não pede mais gente: pede que a mesma fila seja atendida em outra ordem. É uma mudança de processo, não de orçamento.

De onde vem cada número

A cadeia inteira, da base bruta até as horas — para qualquer um refazer a conta.



E AÍ A DECISÃO: QUAL PEDAÇO DA FILA ENCAMINHAR DIRETO

corte	% da fila	acerta	incomoda à toa	horas devolvidas
20% de maior risco	20,0%	84,8%	234 pessoas	699 h
faixa Alto (> 0,80) — adotado	32,9%	82,9%	434 pessoas	1.142 h
Médio + Alto (> 0,65)	73,1%	77,1%	1.287 pessoas	2.366 h

Escolhemos a faixa Alto: devolve 1.142 h e incomoda 434 pessoas à toa. O corte de 20% é a alternativa conservadora — menos horas, menos gente incomodada. É uma decisão de negócio, não de estatística.

DEMONSTRAÇÃO

Kenzie 360 ao vivo

O mesmo cliente, o mesmo assunto — e a decisão mudando conforme ele volta.

Os 49 pesos do modelo treinado estão dentro da página. A conta é a mesma do notebook, e roda sem servidor e sem internet.

O que o Kenzie 360 entrega

Três resultados, todos medidos na base e todos executáveis com a operação que já existe.

1.142 h

de espera devolvidas no semestre

Encaminhando direto a faixa Alto. Sem contratar ninguém: a operação já encaminha 73,8% ao humano — muda a ordem, não o volume.

8.391

conversas que ninguém via passam a ser visíveis

O cliente que desiste em 4,4 min nunca abriu ticket e não existe em relatório nenhum. O modelo dá a ele a nota média mais alta das três faixas.

50,1%

da espera está em três assuntos

Bloqueio de TED/PIX, Onboarding e Câmbio concentram metade de toda a espera do semestre. É o roteiro de produto do próximo ciclo, em ordem.

E cada uma dessas decisões pode ser aberta fator a fator: por que esta conversa recebeu esta nota, e o que mudaria se um fator fosse diferente.

Declaramos: a base é 100% sintética — o projeto demonstra o método, não a magnitude. O desgaste do cliente e os 27% de desistência são premissas nossas. A carga incremental foi demonstrada, não posta em produção, e o retreino automático está desenhado, não implementado.

Obrigado.

Limites declarados e próximos passos

O QUE DECLARAMOS COMO LIMITE

- A base é 100% sintética: demonstra o método, não a magnitude. Trocar por dado real é trocar o arquivo de entrada — a pipeline não muda.
- O desgaste acumulado do cliente e os 27% de desistência são premissas que nós escrevemos no gerador.
- A carga incremental foi demonstrada em um lote novo de 1.227 conversas, não posta em produção.
- O retreino automático está desenhado e não implementado.
- O ambiente está descrito em Terraform e não provisionado.

O QUE VEM DEPOIS

- Classificador de intenção: entender o cliente que escreve em vez de clicar no menu.
- Calibrar os cortes das faixas com a capacidade real da operação, mês a mês.
- Fechar o ciclo de aprendizado: o desfecho de cada conversa vira exemplo novo e realimenta o modelo.
- Agendar a carga incremental em produção.
- Atacar a fila de correção pelos três assuntos que concentram 50,1% da espera.

EM PALAVRAS SIMPLES

Nada aqui é surpresa de última hora: os limites estão escritos nos documentos entregues, e os cinco próximos passos já têm dono e ordem.