

# Features legais e vazamento — guia para a Fase 4

## ⚠ Nota de atualização — 11/09/2026

Este documento foi escrito em 28/08, antes de qualquer treino, e permanece como registro dessa decisão. Três pontos dele foram superados pelo que o projeto mediu depois. A fonte única da verdade para os números do modelo é `Numeros_Oficiais_Modelo13.md`.

**1 • Os números do checklist final estão desatualizados.** O baseline de **74,77%** e o teto de **AUC 0,750** valiam para a população completa e para uma estimativa anterior. Depois de excluir as 4.958 conversas de disparo ativo e ruído, e com o teto recalculado a partir da fórmula do gerador (linha 484 de `gerar_dataset_cde_v8.py`), os valores corretos são **baseline 70,5%** e **teto AUC 0,6736**. O modelo final entrega **0,6729** — 99,6% do teto.

**2 • O modelo final desvia desta regra em três pontos, e isso está declarado.**

| Coluna                           | O que este documento determinou                                   | O que o modelo de 13 variáveis faz | Impacto medido                   |
|----------------------------------|-------------------------------------------------------------------|------------------------------------|----------------------------------|
| <code>arquetipo</code>           | "não usar" — é construção do gerador, não existe na operação real | usa                                | ≈ 0 no drop-one-out              |
| <code>produto_relacionado</code> | listada como derivada de <code>categoria_assunto</code>           | usa                                | ≈ 0 no drop-one-out              |
| <code>categoria_assunto</code>   | deve entrar como a categoria <b>prevista</b> pelo estágio 1       | usa o valor verdadeiro             | é a variável essencial (-0,0684) |

**Nenhum dos três é vazamento do desfecho** — o modelo não vê o resultado da conversa. Os dois primeiros são questão de **portabilidade** (um modelo que dependa de `arquetipo` não pode ser levado para o banco), e o teste de importância mostra que ambos contribuem **zero**: removê-los não altera o AUC. **O resultado não depende deles.**

O terceiro é a limitação real. Em produção só existe a categoria prevista, e a versão rigorosa do modelo deveria usá-la. Este documento antecipou exatamente isso — *"a diferença numérica será pequena, mas a disciplina precisa estar no código, e a banca pode perguntar"*. A diferença é pequena; a disciplina não chegou ao código. **Fica declarado como limitação.**

**3 • A recomendação de respeitar o tempo na divisão foi cumprida, por outro caminho.** A Seção "a divisão também deveria respeitar o tempo" sugeria treinar até uma data de corte e testar depois dela. A separação principal continuou sendo por cliente, mas a recomendação foi atendida em separado: `3_pipeline/10_lote_novo.py` treina até 10/08 e pontua a semana seguinte, com monitor de deriva. Ver `Carga_Incremental_Lote_Novo.md`.

*Nada foi removido do texto original abaixo. Onde ele discordar desta nota, vale a nota.*

**Projeto Kenzie 360 • Sprint 3 • 28/08/2026** Escrito antes de treinar qualquer modelo. Vale para os dois estágios do pipeline.

---

## O problema que este documento evita

A tabela `atendimentos` tem 30 colunas. A maioria delas **só existe depois que a conversa terminou**. Jogar todas num modelo produz um resultado excelente e completamente inútil: o modelo estaria lendo o desfecho para prever o desfecho.

Concretamente: `csat`, `duracao_seg` e `status_conversa` são consequência do que aconteceu. Um modelo com essas colunas acerta quase tudo — e não serve para nada em produção, onde no momento da decisão nenhuma delas existe ainda.

**A regra:** uma feature só é legal se o seu valor estiver disponível **no instante em que o modelo precisa decidir** — a abertura da conversa.

---

## Colunas legais

Disponíveis quando o cliente manda a primeira mensagem.

| Coluna                                                      | Por quê                                                  |
|-------------------------------------------------------------|----------------------------------------------------------|
| <code>primeira_mensagem_cliente</code>                      | É o gatilho da inferência. Insumo principal do estágio 1 |
| <code>idioma</code>                                         | Detectável na primeira mensagem                          |
| <code>segmento_cliente</code>                               | Cadastro                                                 |
| <code>perfil_tecnologico</code> , <code>faixa_etaria</code> | Cadastro                                                 |
| <code>origem</code> (Receptivo / Ativo)                     | O banco sabe se ele mesmo iniciou                        |
| <code>canal_entrada</code>                                  | Conhecido na entrada                                     |
| <code>data_hora</code> → hora, dia da semana                | Conhecido                                                |
| <code>contatos_previos</code>                               | Consulta ao histórico do cliente                         |
| <code>reabertura</code>                                     | Consulta ao histórico do cliente                         |

As duas últimas **só são legais se o sistema consultar o histórico na abertura** — que é exatamente a recomendação da Seção 6.4 da EDA. Se a operação não fizer essa consulta, elas não existem em produção e não podem estar no modelo.

## Sobre `arquetipo`

É construção do gerador, não um campo que exista na operação real. **Não usar.** Um modelo que dependa dele não tem como ser portado para o banco.

---

## Colunas que vazam — não usar em nenhum estágio

| Coluna                                                               | Por que vaza                                                                                  |
|----------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| <code>resolvido_bot</code>                                           | É o alvo do estágio 2                                                                         |
| <code>status_conversa</code>                                         | O desfecho, escrito por extenso                                                               |
| <code>resolucao_declarada</code>                                     | O desfecho                                                                                    |
| <code>sentimento_geral</code>                                        | É o sentimento da <b>última</b> fala do cliente — muda conforme a conversa termine bem ou mal |
| <code>csat</code>                                                    | Só existe depois do atendimento                                                               |
| <code>duracao_seg</code>                                             | Idem                                                                                          |
| <code>num_mensagens</code> ,<br><code>num_mensagens_cliente</code>   | Idem                                                                                          |
| <code>transferencia_iniciada</code> ,<br><code>humano_atendeu</code> | Consequência do fracasso do bot                                                               |
| <code>canal_humano</code>                                            | Só existe se houve transferência                                                              |
| <code>area_encaminhada</code> ,<br><code>motivo_transferencia</code> | Preenchidos no fim, e são derivados do alvo do estágio 1                                      |
| <code>transcricao_completa</code>                                    | Contém a conversa inteira, incluindo a fala de fechamento                                     |
| <code>produto_relacionado</code>                                     | Derivado de <code>categoria_assunto</code> — usar é o mesmo que usar o rótulo                 |
| <code>qtd_dados_mascarados</code>                                    | Depende de quantas falas houve                                                                |

### O caso especial: `categoria_assunto`

É o **alvo do estágio 1**. No estágio 2 ele não pode entrar como valor verdadeiro — precisa entrar como **a categoria prevista pelo estágio 1**.

Usar a categoria verdadeira no estágio 2 daria um resultado otimista que a produção nunca reproduz, porque em produção só existe a previsão. Como o estágio 1 tem teto de 100%, a diferença numérica será pequena — mas a disciplina precisa estar no código, e a banca pode perguntar.

## Duas armadilhas de avaliação

### 1. A divisão treino/teste tem que ser por **CLIENTE**, não por conversa

`contatos_previos` e `reabertura` ligam as conversas de um mesmo cliente. Dividindo por conversa, o mesmo cliente aparece nos dois lados e o modelo memoriza a trajetória dele em vez de aprender o padrão.

Dividir por `id_cliente` : todas as conversas de um cliente ficam ou no treino ou no teste, nunca nos dois.

## 2. A divisão também deveria respeitar o tempo

Em produção o modelo é treinado no passado e aplicado no futuro. Uma divisão que sorteia conversas ao acaso ao longo dos seis meses treina com o futuro. Se der tempo, treinar até uma data de corte e testar depois dela — o que também prepara a demonstração de carga incremental.

Se não der tempo, a divisão por cliente já resolve o problema mais grave. Declarar a escolha no relatório.

---

## Checklist antes de rodar o treino

- ☐ Nenhuma coluna da lista de vazamento entrou no `X`
- ☐ `arquetipo` fora
- ☐ Estágio 2 usa a categoria **prevista**, não a verdadeira
- ☐ Divisão por `id_cliente`
- ☐ Baseline calculado e reportado ao lado do modelo (74,77% para o estágio 2)
- ☐ AUC reportado contra o teto conhecido (0,750)

**Se a acurácia vier muito acima do teto calculado, não comemore — procure o vazamento.** Os tetos foram medidos na base: 100% para o estágio 1, AUC de 0,750 para o estágio 2. Um resultado acima disso significa que uma coluna proibida entrou.