

A deriva traduzida em horas — o lote novo

15/09/2026. Resultado novo, medido hoje. Responde à pergunta do Ilan: "não conseguimos mostrar os resultados do lote novo em tempo de horas ganhas para os clientes?"

Conseguimos — e com tempo real de cada conversa, não com média aplicada por cima.

Como a conta é feita

O `09d_tempo_ate_humano.py` já calcula, para cada conversa, o `min_ate_humano` : o intervalo entre a primeira mensagem do cliente e a primeira fala do atendente. É o tempo que a pessoa passa com a Kenzie **antes** de falar com um humano — não a duração total do atendimento.

São 13.567 conversas no semestre, média de 13,1 min, total de 2.966 h. É a base da conta de espera evitável do Caso de Negócio.

O `16_horas_lote_novo.py` cruza esse tempo com as duas populações pontuadas pelo modelo e devolve as horas por faixa de risco.

A coluna que importa é `horas_por_1000` : horas de espera a cada mil conversas que entram na fila. Sem ela a comparação seria 744 h contra 120 h — números de populações de tamanhos diferentes, que não dizem nada.

Os números

Espera evitável, a cada 1.000 conversas da fila

	Baixo	Médio	Alto	Total
Histórico — 7.712 conversas	20 h	39 h	37 h	96 h
Lote novo — 1.227, última semana	15 h	33 h	50 h	98 h
Variação	-5 h	-6 h	+13 h (+35%)	+2 h

O que sustenta cada linha

	Histórico	Lote novo
conversas que chegam a um humano	3.414 (44,3%)	550 (44,8%)
espera total medida	744 h	120 h
tempo médio de menu	13,1 min	13,1 min
precisão da faixa Alto	82,9%	86,3%
falsos alarmes na faixa Alto	434	72

A leitura — e é melhor do que parecia

A espera total praticamente não mudou: **96 h → 98 h por mil conversas**. O que mudou foi **onde** ela está. Treze horas migraram das faixas Baixo e Médio para a faixa Alto.

Ou seja: a fila não ficou mais lenta. Ela ficou **mais concentrada** — e concentrada exatamente no grupo que o modelo manda encaminhar primeiro.

Três consequências, e as três são boas para a defesa:

1. **A política de encaminhar a faixa Alto rende mais nessa semana:** devolve 50 h por mil conversas, contra 37 h no histórico. Mesmo esforço operacional, 35% mais espera devolvida.
2. **Com menos gente incomodada à toa:** a precisão da faixa Alto subiu de 82,9% para 86,3%. O trade-off melhorou nas duas pontas.
3. **O monitor deixa de ser abstrato.** "A faixa Alto subiu 10 pontos" é uma frase de cientista de dados. "Treze horas de espera a cada mil conversas migraram para o grupo de maior risco" é a mesma coisa em linguagem de operação.

Consistência com os números oficiais

As 284 h da faixa Alto no conjunto de teste, escaladas pelo fator de 4,03 (teste → semestre), dão 1.145 h — contra as **1.142 h** publicadas no `Numeros_Oficiais_Modelo13.md`. A diferença é arredondamento do fator. **O método reproduz o número oficial**, o que é a melhor evidência de que a conta nova está certa.

As ressalvas, que continuam valendo

- **Uma semana, 1.227 conversas, base sintética.** Nada aqui é projeção anual.
 - **O lote novo é mais fácil** por ter mais cliente reincidente — mesma ressalva do AUC 0,7003. A precisão maior da faixa Alto tem a mesma origem, e isso precisa ser dito junto.
 - **Os 13,1 min são tempo de menu**, não duração do atendimento (essa é 24,5 min). Confundir os dois infla a conta em quase o dobro.
 - A espera **evitável** pressupõe que encaminhar direto elimina o tempo de menu. Na prática elimina a maior parte, não tudo.
-

No painel

Fonte nova: `vw_monitoramento_horas` (6 linhas).

Gráfico, ao lado do de distribuição:

Campo	Valor
Tipo	Coluna agrupada
Dimensão	faixa_operacional
Dimensão de detalhamento	origem
Métrica	horas_por_1000 · agregação Média
Classificar	faixa_ordem crescente
Classificação secundária	origem_ordem crescente

Título: "A espera evitável migrou para a faixa Alto".

Indicador: métrica `horas_por_1000`, filtros `faixa_operacional = Alto` e `origem_ordem = 2`. Dá 50 h — o número que resume a página.

Nunca use a coluna `horas_espera` num gráfico que compare as duas origens: 744 h contra 120 h é comparação entre populações de tamanhos diferentes. A coluna comparável é `horas_por_1000`.

Na apresentação

Uma frase, no slide de monitoramento:

"O monitor não disparou só em percentual. Em horas: a cada mil conversas, treze horas de espera migraram para a faixa de maior risco — e encaminhar essa faixa passou a devolver 50 horas em vez de 37, com precisão maior. A fila não ficou mais lenta; ficou mais concentrada onde o modelo aponta."