

Kenzie 360 — Entrega Final

MBA em Engenharia de Dados • Universidade Presbiteriana Mackenzie • 2026 Ilan David Schapira • Giovanna Caetano Protti • Jonathas Borges Orientação: Prof. Gustavo Ferreira

O que é este projeto

O **Kenzie 360** é a camada de inteligência da assistente virtual de um banco. O caso de uso: o Banco Kenzie atende pelo WhatsApp clientes **não residentes**, que mantêm no Brasil uma conta de domiciliado no exterior (CDE). A assistente, **Kenzia**, funciona e não tem memória — cada conversa começa do zero e nenhuma vira aprendizado.

O projeto não é um bot novo. É o cérebro que o bot consulta: uma camada que guarda o histórico por cliente, estima **no minuto zero da conversa** a chance de a Kenzia não resolver, e publica essa nota para a operação usar como ordem de fila.

A base é 100% sintética. Foi gerada por script do próprio grupo, calibrada por indicadores agregados de uma operação real (volume, curva horária, capacidade da equipe). Nenhuma conversa de cliente real foi usada. O trabalho demonstra o **método**, não a magnitude.

Onde está cada item do escopo

Item do escopo (MACK_HANDS_00 . pdf)	Onde está nesta entrega
1 • Visão de negócio	2_documentos/Briefing_Projeto_Kenzie360_Consolidado.pdf e Definicao_Produto_MVP.md
2 • Storytelling + modelo preditivo	1_apresentacao/ • 2_documentos/Numeros_Oficiais_Modelo13.md • 3_pipeline/09_modelo_risco_bot.py
3 • Boas práticas de governança	2_documentos/Item3_Governanca.md
4 • Arquitetura Lake / Lakehouse	2_documentos/Kenzie360_Arquitetura_Lambda_GCP_v2.pdf • 3_pipeline/01_ a 06_ • repositório (infra/)
5 • Trilhas de carreira e atuação dos perfis	2_documentos/Item5_Trilhas_de_Carreira.md

Os números oficiais

A fonte única da verdade é `2_documentos/Numeros_Oficiais_Modelo13.md`. Qualquer documento que discorde dele está desatualizado. Os principais:

Base	36.000 conversas · 405.073 mensagens · 17/02 a 17/08/2026
População do modelo	31.042 demandas reais (excluídos 4.958 de disparo ativo e ruído)
Treino / teste	23.330 / 7.712 · separados por cliente · zero clientes em comum
Baseline / acurácia @0,50	70,5% / 72,8%
AUC / Gini	0,6729 / 0,3457
Teto teórico da base	0,6736 → 99,6% do sinal capturado
Faixas operacionais	Baixo 26,9% · Médio 40,2% · Alto 32,9%
Resolução por faixa	47,5% · 27,6% · 17,1%
Espera evitável	2.966 h no semestre · 1.142 h encaminhando a faixa Alto
Custo dessa decisão	precisão 82,9% · 434 falsos alarmes

O modelo foi **reproduzido em duas máquinas diferentes**, com resultado idêntico até a quarta casa decimal.

Estrutura do pacote

```
Entrega_Final_Kenzie360/
├─ LEIA-ME_Entrega_Final.md      ← este arquivo
├─ 1_apresentacao/              deck da banca e roteiro
├─ 2_documentos/                briefing, os 5 itens do escopo, números e decisões
├─ 3_pipeline/                  todos os scripts, em ordem de execução, + notebook
├─ 4_modelo/                    coeficientes e scores publicados
├─ 5_simulador/                 a demonstração do MVP (abre no navegador, sem
servidor)
├─ 6_painel/                    o painel no Looker Studio (PDF e link)
```

Como rodar a pipeline, na ordem

Todos os scripts usam caminhos relativos e são idempotentes — podem rodar mais de uma vez.

Ordem	Script	O que faz
1	<code>00_teste_conexao.py</code>	confere credencial e acesso ao projeto
2	<code>01_carga_bronze.py</code>	envia os CSVs ao Cloud Storage e carrega a bronze, acrescentando <code>_ingestion_ts</code> e <code>_source_file</code>
3	<code>02_cria_silver.py</code>	tipa, deduplica por chave de negócio e mascara
4	<code>06_cria_gold.py</code>	cria as views da camada gold
5	<code>09_modelo_risco_bot.py</code>	treina o modelo de 13 variáveis e grava o score
6	<code>09c_ / 09d_</code>	fila de correção por assunto e tempo até o humano
7	<code>10_lote_novo.py</code>	carga incremental e monitor de deriva
8	<code>11_ a 16_</code>	publicam score, painel e monitoramento na gold

Pré-requisitos: Python 3, `pip install -r requirements.txt`, e `gcloud auth application-default login`.

O que este trabalho declara como limite

Está escrito em todos os documentos e foi dito na apresentação:

- **A base é sintética.** O projeto demonstra o método, não a magnitude que apareceria no banco.
- **O desgaste acumulado do cliente** (a autonomia caindo de 30,9% para 22,5%) é **premissa modelada no gerador**, publicada como parâmetro — não é achado empírico.
- **Os 27% de conversas que não chegam a ninguém** vêm de um parâmetro do gerador. Como a base escalona ~72% dos casos não resolvidos, 27% é piso, não teto.
- **A carga incremental foi demonstrada**, não posta em produção.
- **O retreino automático está desenhado**, não implementado.
- **O ambiente está descrito em Terraform**, com `plan` verde; o `apply` não foi executado. Os recursos foram criados no início do projeto e o Terraform os adota via `terraform import`.
- **Um modelo de NLP treinado sobre texto sintético aprende o padrão do gerador**, não o do cliente. Foi por isso que o texto livre não entrou no modelo, e é por isso que o classificador de intenção é o próximo passo, não parte desta entrega.

Dois erros que corrigimos publicamente

Registrados porque fazem parte do método, não apesar dele.

O classificador de 99,99%. O primeiro modelo do projeto tinha 99,99% de acurácia. Ele lia o assunto da conversa num texto que o próprio sistema havia escrito a partir do assunto — recuperava uma resposta que já estava na tabela. O número era real e não significava nada. Foi descartado. A regra que ficou: **quando o modelo acerta quase tudo, desconfie da variável.**

O denominador dos 32%. A taxa de falha do atendimento humano foi publicada como 32,0% com um denominador que excluía três em cada cinco casos resolvidos. Corrigida para 15,9% — e **duas conclusões que dependiam dela foram retratadas.**

Repositório

O código-fonte, a infraestrutura como código e a esteira de CI/CD estão no repositório do projeto, descrito em `2_documentos/Repositorio_GitHub.md`. O que está lá e não neste pacote:

- `infra/` — Terraform dos três datasets e do bucket, com módulo e ambientes
- `.github/workflows/` — a esteira que valida, simula e espera aprovação humana
- histórico de commits e pull requests das cinco sprints